GR308 Qwen3.8-27B

三套推理框架 Baseline 数据报告

FANT vLLM Eager · SGLang + GR308 兼容层 · FANT vLLM Graph32

37.50	44.26	12/12
Formal 峰值 output tok/s Graph32 · C32	稳定性 output tok/s Graph32 · C64	三方案前后哨兵 全部通过

报告日期：2026-09-10
证据状态：三套正式运行 validation 均为 passed；报告为系统级描述性比较。

1. 执行摘要

主要结论

FANT Graph32 是本轮中低并发性能上限：Formal 在 C1/C8/C16/C32 相对 FANT vLLM Eager 分别提高 231.4%、153.0%、82.6%、41.9%。但 C64 超出冻结的 Graph capture bucket，Formal 仅比 Eager 高约 1.2%，同口径稳定性吞吐也仅高 0.4%。

- FANT vLLM Eager 随并发增加持续扩展，Formal 从 C1 的 1.6428 tok/s 增至 C64 的 32.0792 tok/s。
- SGLang 在 C1 的 Formal 吞吐比 Eager 高 32.1%，但 C8–C64 扩展明显受限；C64 仅为 Eager 的 19.8%。
- Graph32 的 Formal 峰值出现在 C32（37.5037 tok/s）；C64 回落 13.5%，显示 capture bucket 内与 bucket 外饱和点的行为不同。
- 三套正式结果均通过请求完整性、稳定性和正确性门禁；所有 Formal 点均为 3 个 engine-cold block，CV 均低于 0.6%。

结论边界

三套运行没有随机交错；框架、兼容层、算子实现和运行时路径同时变化。本文不报告 p 值，不使用“显著优于”措辞，也不把差异单独归因于调度器或 Graph。

2. 测试对象与实验口径

项目	冻结配置
服务器	Ubuntu 22.04；2× AMD EPYC 9654；224 逻辑 CPU；约 1 TiB 内存；2 个 NUMA node
加速卡	4× Fantasy GR308；每卡 57,344 MiB（约 56 GiB），物理总显存约 224 GiB
设备映射	逻辑设备 0/2/4/6，各对应一张物理卡的 .0 function；4 卡位于 NUMA0
模型	本地 /data/models/Qwen3.8-27B；BF16；TP=4；served name qwen3.8-27b
公共限制	max model length 32768；text-only；OpenAI-compatible 客户端；固定 token ID；ignore_eos=true

方案	执行路径	定位
FANT vLLM Eager	厂商适配 vLLM；eager execution	可运行基础性能基线
SGLang + GR308 兼容层	SGLang upstream + 兼容适配；torch_native attention；radix cache 关闭	另一开源框架适配基线
FANT vLLM Graph32	厂商 Graph；capture bucket=1/2/4/8/16/32	现有厂商栈性能上限参考

阶段	输入→输出	并发	请求数	重复/条件
Rapid	128→64	1/8/16/32/64	8/16/32/64/128	单轮筛查
Formal	1024→256	1/8/16/32/64	12/16/32/64/128	3 个 engine-cold block
稳定性主段	128→64	64	1024	三方案同口径
稳定性扩展	128→64	64	512	主段不足 60 分钟时执行
正确性哨兵	结构化任务	—	12 cases	性能前后各一次

主指标为客户端验证的 completed output tokens per second，越高越好。TTFT、TPOT、E2E 延迟以成功请求为单位；正确性哨兵只验证冻结的 12 个精确任务，不构成业务质量认证。

3. Formal 核心吞吐结果

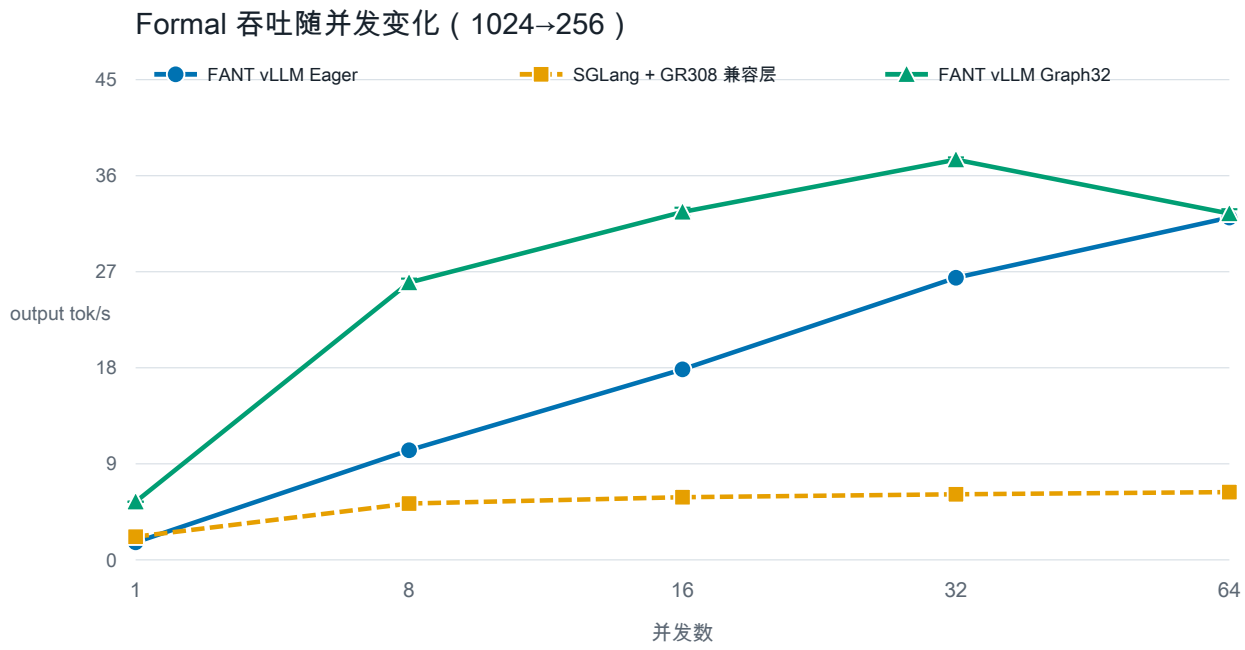


图 1 | Formal（1024→256）吞吐扩展曲线。每点为 3 个 engine-cold block 的均值，误差条为描述性 95% t 区间（n=3）；不用于细小差异的显著性推断。

并发	Eager mean±SD	SGLang mean±SD	Graph32 mean±SD	Graph/Eager	SGLang/Eager
1	1.6428 ± 0.0032	2.1703 ± 0.0089	5.4443 ± 0.0059	3.314×	1.321×
8	10.2715 ± 0.0287	5.2778 ± 0.0056	25.9846 ± 0.1486	2.530×	0.514×
16	17.8511 ± 0.0650	5.8712 ± 0.0104	32.6009 ± 0.1605	1.826×	0.329×
32	26.4358 ± 0.0180	6.1444 ± 0.0067	37.5037 ± 0.0843	1.419×	0.232×
64	32.0792 ± 0.1211	6.3494 ± 0.0063	32.4532 ± 0.1630	1.012×	0.198×

读图重点

• Graph32 在 C1–C32 显著改变了系统的吞吐扩展形状；最大均值为 C32 的 37.5037 tok/s。这里的“显著”仅指幅度明显，不是统计显著性术语。

• Eager 在 C64 达到 32.0792 tok/s；Graph32 在 C64 为 32.4532 tok/s，两者仅相差 1.2%。

• SGLang C8 后趋于平台化，C8→C64 仅由 5.2778 增至 6.3494 tok/s，表现出明显的并发扩展差距。

4. Rapid 与短输出响应能力

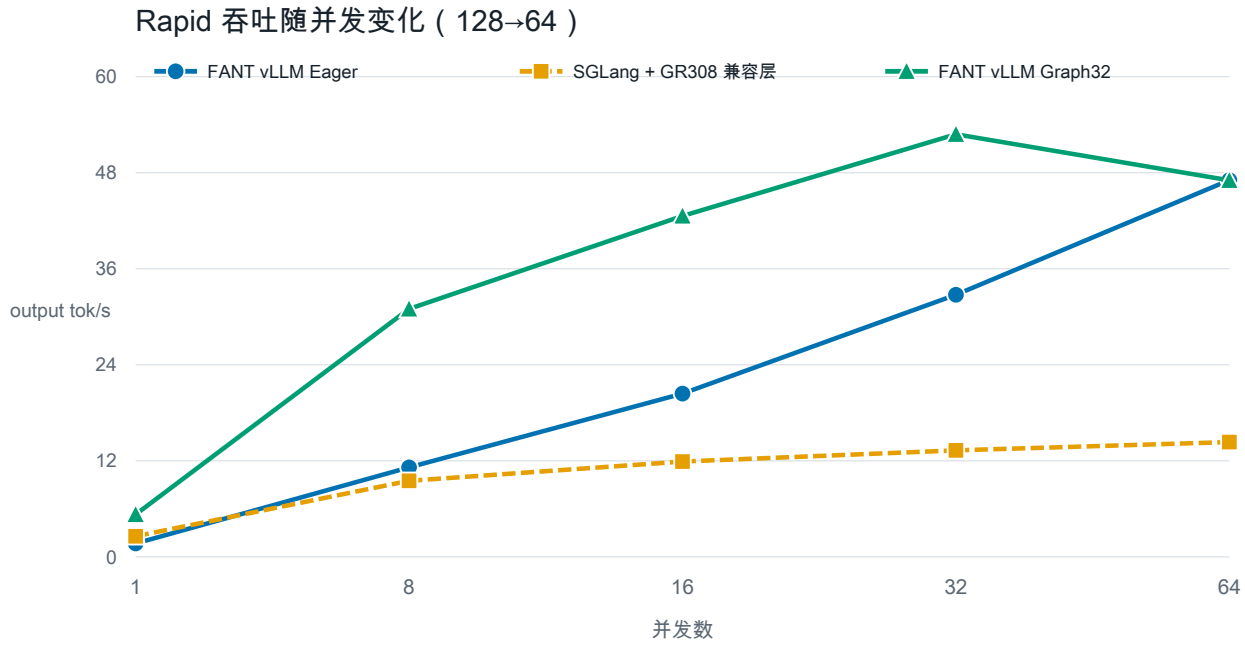


图 2 | Rapid（128→64）吞吐扩展曲线。该阶段为单轮快速筛查，没有跨 block 误差估计；用于观察形状，不替代 Formal 结论。

并发	FANT vLLM Eager	SGLang	FANT Graph32	Graph 相对 Eager
1	1.6748	2.5734	5.2969	+216.3%
8	11.1785	9.5036	30.9800	+177.1%
16	20.3973	11.9078	42.5933	+108.8%
32	32.7470	13.3061	52.8004	+61.2%
64	47.0706	14.3410	47.0459	-0.1%

关键观察

Graph32 在 Rapid C32 达到 52.8004 tok/s，随后在 C64 回落到 47.0459 tok/s；Eager C64 为 47.0706 tok/s，几乎完全相同。短输出与 Formal 都指向同一个边界：Graph 优势集中在捕获桶覆盖的 C1–C32。

5. 稳定性、延迟与正确性

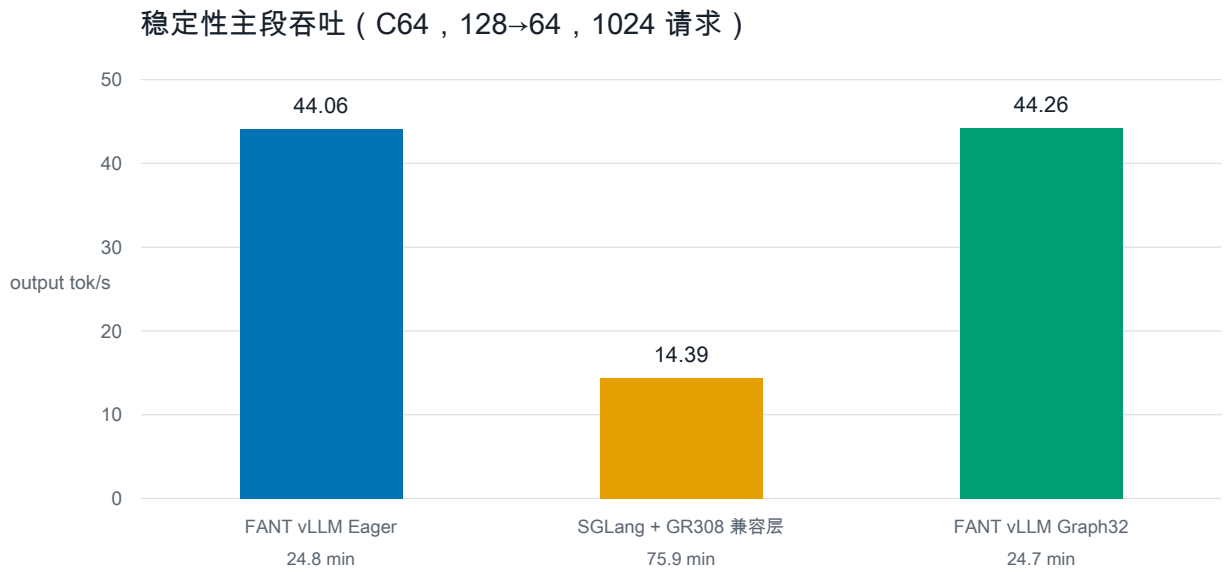


图 3 | 三方案同口径稳定性主段：C64、128→64、1024 请求。柱上为吞吐，柱下为主段持续时间。三组均为 1024/1024 成功。

方案	成功请求	吞吐 tok/s	持续时间	扩展段
FANT vLLM Eager	1024/1024	44.0619	24.8 min	512/512，44.3500 tok/s
SGLang + GR308 兼容层	1024/1024	14.3865	75.9 min	按 ≥60 min 条件跳过
FANT vLLM Graph32	1024/1024	44.2578	24.7 min	512/512，46.2399 tok/s

5.1 同口径稳定性请求延迟

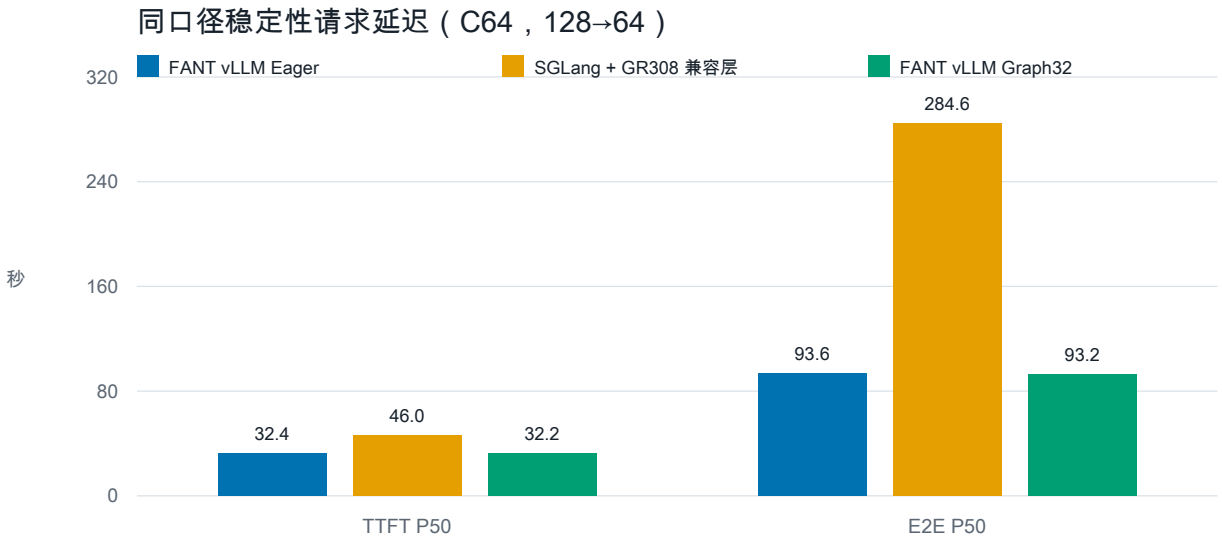


图 4 | 同口径稳定性请求的 P50 延迟。TTFT 为首 token 延迟，E2E 为整请求完成延迟；单位为秒。SGLang 数据从 1024 条请求级记录重新计算。

方案	TTFT P50	TTFT P95	TPOT P50	E2E P50	E2E P95
FANT vLLM Eager	32.42s	40.84s	914.2ms	93.58s	94.41s
SGLang + GR308 兼容层	46.03s	46.15s	3788.7ms	284.60s	285.49s
FANT vLLM Graph32	32.24s	40.70s	914.1ms	93.19s	94.41s

方案	性能前哨兵	性能后哨兵	结论
FANT vLLM Eager	记录通过	12/12	通过
SGLang + GR308 兼容层	12/12	12/12	通过
FANT vLLM Graph32	12/12	12/12	通过

注：Eager 的正式 validation 明确记录 post sentinel 12/12；其报告与证据链记录 pre sentinel 已执行，但汇总 JSON 未单列 pre 数字，因此此处保持原证据措辞，不补造 12/12。

6. 统计可信度与解释边界

并发	Eager CV	SGLang CV	Graph32 CV	最大 CV
1	0.195%	0.408%	0.109%	0.408%
8	0.279%	0.106%	0.572%	0.572%
16	0.364%	0.177%	0.492%	0.492%
32	0.068%	0.108%	0.225%	0.225%
64	0.377%	0.099%	0.502%	0.502%

• 单位：Formal 的 engine-cold block；每个框架、每个并发
n=3。请求行不是独立重复实验，不能把单请求数量当作统计样本量。

• 不确定性：表格与图 1 使用样本标准差和描述性 95% t 区间；n=3 时区间对分布假设敏感。

• 推断限制：运行顺序未随机化、未交错，宿主页缓存和驱动状态可能保持热态；因此不执行框架间 t 检验/ANOVA，也不报告 p 值。

• 机制限制：SGLang、Eager 与 Graph32
同时改变框架与底层执行路径。观察到的差异是系统级效应，不能直接等同于调度器、算子或 Graph 的单独贡献。

• C64 限制：Graph capture bucket 冻结为 1/2/4/8/16/32；C64 是 bucket 外 saturation/stress 点。

• 质量限制：固定 token ID、ignore_eos=true 的合成 workload 适合性能诊断，但不代表真实提示分布、业务 goodput、生产 SLA 或模型质量。

允许使用的结论

“在本次冻结配置和合成负载下，Graph32 在 C1–C32 的描述性吞吐明显高于 Eager 与 SGLang；C64 与 Eager 接近。”

禁止扩大的结论

不能写成“Graph32 在所有并发下显著优于其他框架”“差异由调度器导致”或“这些吞吐可直接作为生产 SLA”。

附录 A | 完整 Formal 数值

方案	并发	三个 engine-cold block（tok/s）	mean	SD	CV	描述性 95% CI
FANT vLLM Eager	1	1.6391, 1.6443, 1.6450	1.6428	0.0032	0.195%	[1.6349, 1.6507]
FANT vLLM Eager	8	10.2714, 10.3002, 10.2429	10.2715	0.0287	0.279%	[10.2003, 10.3427]
FANT vLLM Eager	16	17.7820, 17.9111, 17.8602	17.8511	0.0650	0.364%	[17.6895, 18.0127]
FANT vLLM Eager	32	26.4181, 26.4354, 26.4541	26.4358	0.0180	0.068%	[26.3911, 26.4806]
FANT vLLM Eager	64	32.2150, 31.9827, 32.0398	32.0792	0.1211	0.377%	[31.7784, 32.3799]
SGLang + GR308 兼容层	1	2.1601, 2.1757, 2.1752	2.1703	0.0089	0.408%	[2.1483, 2.1923]
SGLang + GR308 兼容层	8	5.2717, 5.2827, 5.2788	5.2778	0.0056	0.106%	[5.2638, 5.2917]
SGLang + GR308 兼容层	16	5.8592, 5.8778, 5.8764	5.8712	0.0104	0.177%	[5.8453, 5.8970]
SGLang + GR308 兼容层	32	6.1368, 6.1493, 6.1471	6.1444	0.0067	0.108%	[6.1279, 6.1609]
SGLang + GR308 兼容层	64	6.3423, 6.3544, 6.3514	6.3494	0.0063	0.099%	[6.3337, 6.3650]
FANT vLLM Graph32	1	5.4385, 5.4504, 5.4441	5.4443	0.0059	0.109%	[5.4296, 5.4591]
FANT vLLM Graph32	8	25.8946, 25.9031, 26.1561	25.9846	0.1486	0.572%	[25.6155, 26.3537]
FANT vLLM Graph32	16	32.5962, 32.7637, 32.4428	32.6009	0.1605	0.492%	[32.2022, 32.9996]
FANT vLLM Graph32	32	37.4078, 37.5660, 37.5374	37.5037	0.0843	0.225%	[37.2944, 37.7130]
FANT vLLM Graph32	64	32.2816, 32.4721, 32.6059	32.4532	0.1630	0.502%	[32.0483, 32.8581]

附录 B | 证据位置

方案	服务器正式结果目录	本地机器可读摘要
FANT vLLM Eager	/data/infra/benchmarks/gr308-vllm-baseline-20260907T095637Z	/Desktop/Work/GR308/docs/benchmarks/gr308-vllm-baseline-20260907T095637Z/baseline-summary.json
SGLang + GR308 兼容层	/data/infra/benchmarks/gr308-sglang-baseline-20260908T053931Z	/Desktop/Work/GR308/docs/benchmarks/gr308-sglang-baseline-20260908T053931Z/analysis/sglang-baseline-summary.json
FANT vLLM Graph32	/data/infra/benchmarks/gr308-vllm-fant-graph-20260909T141559Z	/Desktop/Work/GR308/docs/benchmarks/gr308-vllm-fant-graph-20260909T141559Z/analysis/baseline-summary.json

FANT Graph 的三次启动失败尝试分别保存在 20260909T135112Z、20260909T135742Z、20260909T140333Z 目录，并带 EXCLUDED_RUN.json；它们未进入正式统计。SGLang 的 1024→256 长上下文稳定性结果保留为补充压力证据，不进入同口径稳定性比较。