性能测试数据研究报告

风华 GR308 Qwen 系列并发性能测试与调优报告

vLLM 0.18.0 | BF16 | C1 / C16 | MTP 与 CUDA Graph 参数优化 | 35B 二次短测更新

测试对象：Qwen3.6-35B-A3B、Qwen3.5-9B、Qwen3-30B-A3B、Qwen3-Next-80B-A3B-Instruct。

测试平台：4 张 GR308 物理卡、8 个逻辑 GPU；每个逻辑 GPU 约 56 GiB GDDR6、1008 GB/s；驱动 1.1.0.19。

测试工具：vLLM bench serve；temperature=0、ignore-eos、request-rate=inf。前三个模型输入/输出 3072/1024，80B 输入/输出 1024/1024。

C16 最高聚合吞吐	C16 最高 Decode TPS	验证完成度
247.16 tok/s Qwen3.5-9B	18.90 tok/s Qwen3.5-9B	3 正式 + 2 短测 35B 新候选待正式复测

一、结论摘要

结论 1 | 9B 吞吐领先。双 TP1 / DP2、MTP4 配置在 C16 达到 247.16 tok/s 聚合吞吐和 18.90 Decode Avg TPS，相对对照表提升 57.9%。

结论 2 | 80B 高并发达标。TP4、MTP1、Graph64 在 C16 达到 16.20 Decode Avg TPS，较对照提升 7.9%；TTFT 降至 3.53 s，改善 41.7%。

结论 3 | 30B 偏向吞吐。无 EP 的 TP2 配置使 C16 Decode Avg TPS 提升 30.1%，但 TTFT 增加 24.8%，适合吞吐优先而非低延迟场景。

结论 4 | 35B 新候选显著增益。MTP4、Graph64、batch4096 的 D 组短测在 C16 达到 180.64 tok/s 聚合吞吐和 13.93 Decode Avg TPS；相对对照 TPS 提升 9.3%，TTFT 改善 4.7%。该结果尚待 64+64 正式复测。

结论 5 | 自定义 all-reduce 始终保持启用。所有有效结果均未使用 --disable-custom-all-reduce；80B 自动 KV 组启动失败，固定 8 GiB 更稳定。

二、测试口径

项目	定义	本次状态
并发档位	C1 与 C16；C1 串行、C16 最大并发 16	四模型覆盖
正式测试	C1/C16 各 64 prompts	35B 原正式基线、9B、30B
最新短测	C1 16 prompts；C16 32 prompts	35B 新候选、80B；均待正式复测
Decode Avg TPS	1000 / mean TPOT(ms)，代表平均解码速率	与对照表同口径
聚合吞吐	并发窗口内总 output token throughput	用于高吞吐方案排序

说明：对照表数值用于描述性比较。35B 与 80B 当前展示最新短测候选，不能直接作为正式验收结果；9B 的双 TP1 / DP2 与对照 TP2、30B 的无 EP TP2 与对照 EP+TP2 并非严格同配置。

三、四模型测试结果与对照

模型	并发	TTFT 实测	TTFT 对照	TTFT 变化	Decode 实测	Decode 对照	TPS 变化	聚合吞吐
Qwen3.6-35B-A3B*	C1	1537.19	1731.87	-11.2%	50.75	52.91	-4.1%	47.21
	C16	3321.47	3487.11	-4.8%	13.93	12.74	+9.3%	180.64
Qwen3.5-9B	C1	2335.93	1545.07	+51.2%	54.64	45.09	+21.2%	48.62
	C16	3501.62	2487.47	+40.8%	18.90	11.97	+57.9%	247.16
Qwen3-30B-A3B	C1	1054.43	1245.71	-15.4%	26.43	26.85	-1.6%	25.76
	C16	4225.69	3384.84	+24.8%	15.22	11.70	+30.1%	225.67
Qwen3-Next-80B-A3B*	C1	595.37	1072.45	-44.5%	28.86	33.23	-13.2%	28.41
	C16	3528.79	6048.71	-41.7%	16.20	15.02	+7.9%	231.98

Qwen3.6-35B-A3B：D 组短测 C1 Decode Avg TPS 为 50.75，距对照缩小至 4.1%，TTFT 改善 11.2%；C16 Decode Avg TPS 达到 13.93、提升 9.3%，TTFT 同时改善 4.7%。相对上一正式配置，C16 聚合吞吐提升约 8.0%，但 TTFT 增加约 24.4%。

Qwen3.5-9B：C1/C16 Decode Avg TPS 分别提升 21.2% 和 57.9%，吞吐收益最大；相应 TTFT 增加 51.2% 和 40.8%，体现双 TP1 / DP2 的吞吐优先取向。

Qwen3-30B-A3B：C1 TTFT 改善 15.4%，Decode Avg TPS 基本持平；C16 Decode Avg TPS 提升 30.1%，但 TTFT 增加 24.8%。

Qwen3-Next-80B-A3B：C1 TTFT 改善 44.5%，但 Decode Avg TPS 低 13.1%；C16 同时实现 TPS +7.9% 和 TTFT -41.7%，是最明确的综合改善。

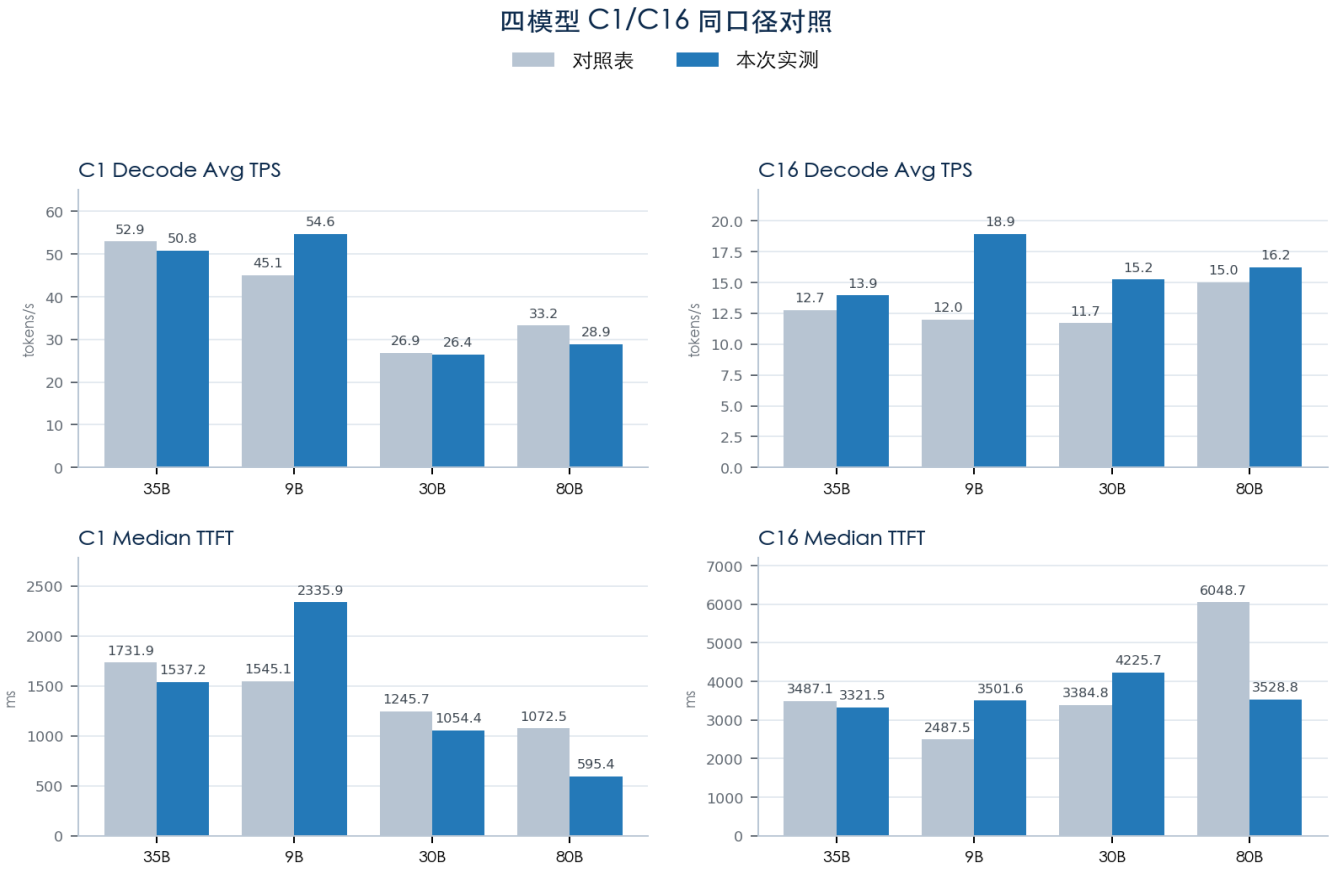
方向说明：绿色表示相对对照改善，红色表示退化。TTFT 的负变化为改善，TPS 的正变化为改善。带 * 的 35B、80B 为短测候选。

四、资源与可比性

模型	拓扑	输入/输出	样本量	与对照可比性
35B*	TP2 / 1 物理卡	3072 / 1024	16 + 32；原正式 64 + 64	同 TP2/负载；新候选为短测
9B	双 TP1 / DP2 / 1 物理卡	3072 / 1024	64 + 64	有限：对照为 TP2
30B	TP2、无 EP / 1 物理卡	3072 / 1024	64 + 64	有限：对照为 EP+TP2
80B	TP4 / 2 物理卡	1024 / 1024	16 + 32	短测：负载相同、样本量较少

五、性能图表

图 1：四个模型在 C1/C16 下的 Decode Avg TPS 与 Median TTFT。同一模型内部与对照表比较；不同模型因拓扑与输入长度不同，不按绝对数值推导模型优劣。



六、图表解读

吞吐观察：9B 的 C16 18.90 Decode Avg TPS 与 247.16 tok/s 聚合吞吐仍为四模型最高。35B D 组把 C16 Decode Avg TPS 提升至 13.93、聚合吞吐提升至 180.64，首次同时超过对照 TPS 与 TTFT。

延迟观察：35B D 组相对对照的 C1/C16 TTFT 均改善，但相对上一正式配置，C16 TTFT 从 2671 ms 增至 3321 ms。80B 的 C1/C16 TTFT 均大幅低于对照；9B 与 30B 的吞吐配置仍存在延迟代价。

决策变化：35B 的部署候选由 MTP3 / batch2048 更新为 MTP4 / batch4096，但必须先完成正式复测。生产部署仍不宜只设一个统一参数；80B 可将 batched tokens 4096 作为低 TTFT 备选。

统计限制：当前每个最终配置只有一个固定 seed 的结果；没有重复运行、标准差或置信区间，因此报告不作显著性结论。

七、35B 调优矩阵与跨卡验证

候选	关键差异	C1 Decode	C16 Decode	C16 聚合	C16 TTFT	判断
原正式	MTP3 / G1-128 / b2048	47.40	11.78	167.31	2671 ms	正式基线
A	MTP4 / G4-64 / b2048	50.76	13.65	175.57	5594 ms	有效
B	MTP4 / G4-128 / b2048	50.81	13.58	176.49	4973 ms	C1 最优
C	MTP4 / G4-64 / b3072	50.18	13.56	176.41	4819 ms	中间档
D	MTP4 / G4-64 / b4096	50.75	13.93	180.64	3321 ms	短测最优
E	MTP3 / G4-64 / b2048	47.67	12.53	164.38	4623 ms	MTP3 对照
F	MTP3 / G4-64 / b4096	47.14	12.36	140.61	4344 ms	排除

D 组为单轮短测（C1 16 prompts、C16 32 prompts），全部请求成功；相对原正式配置的吞吐提升需要通过跨卡重复和 64+64 prompts 正式测试确认。

八、80B 短测矩阵

组别	配置	C1 Decode	C16 Decode	C16 聚合	C16 TTFT	判断
A	Eager / 无 MTP / 8 GiB	10.82	11.61	177.71	3515 ms	基线
B	Eager / MTP1 / 8 GiB	26.28	16.01	231.30	3308 ms	MTP 有效
C	MTP1 / Graph32 / 8 GiB	28.93	16.03	228.68	3205 ms	C1 最优
D	MTP1 / Graph64 / 8 GiB	28.86	16.20	231.98	3529 ms	吞吐最优
E	Graph64 / 自动 KV	-	-	-	-	启动失败
F	Graph64 / batch4096	28.63	16.02	230.99	2975 ms	TTFT 最优
G	Graph64 / batch4096 / async	28.90	15.84	228.07	4760 ms	排除

调优判断：MTP1 是 80B 的主要增益来源；Graph32/64 进一步提升 C1。自动 KV 在本轮引擎初始化失败，async 则降低 C16 吞吐并增加 TTFT。

九、最终配置与部署建议

模型	并行 / MTP	Graph	Batched tokens	KV / Block	调度	建议
35B*	TP2 / MTP4	4,8,16,32,64	4096	自动 / 1088	同步	待正式复测
9B	TP1 + DP2 / MTP4	4,8,16,32	4096	自动 / 800	同步	吞吐优先
30B	TP2 / 无 MTP / 无 EP	4,8,16,32	4096	8 GiB / 800	async	吞吐优先
80B	TP4 / MTP1	4,8,16,32,64	2048	8 GiB / 1088	同步	待正式复测

统一约束：精度均为 BF16；自定义 all-reduce 保持启用，不加入 --disable-custom-all-reduce；关闭 prefix caching；max model length 4096；max num seqs 16。

35B：最新高吞吐候选为 D 组（MTP4 / Graph64 / batch4096）。其 C16 Decode TPS 和聚合吞吐均高于原正式配置，但当前仅为短测；上线前必须完成跨卡重复与 64+64 prompts 正式复测。若更重视 C16 TTFT，可继续保留原 MTP3 / batch2048 配置。

9B：双 TP1 / DP2 适合吞吐型服务。若业务更重视首包延迟，应保留 TP2 低延迟配置作为独立服务档位，不应以当前高吞吐配置替代所有场景。

30B：无 EP 的 TP2 在当前软件栈下稳定且 C16 吞吐高。EP 未证明能稳定带来收益，不建议在正式配置中强制启用。

80B：高吞吐首选 Graph64 / batch2048；如更重视 C16 TTFT，可选 Graph64 / batch4096，Decode Avg TPS 仅从 16.20 降至 16.02，而 TTFT 从 3529 ms 降至 2975 ms。正式上线前必须补跑 64+64 requests。

十、运行边界、异常与结论

已知异常：并发启动多个 FHCCL/RCCL communicator 时，35B 初始候选出现通信初始化失败；固定 75 秒错峰仍不足，改为上一服务 API ready 后再启动下一通信域后，六组短测全部完成且请求零失败。80B 自动 KV 组在 EngineCore 初始化阶段失败。上述异常均未造成硬件健康告警。

硬件状态：测试结束后 8 个逻辑设备均为 OK，显存回落至约 540 MiB；四张物理卡空闲。服务器为双路 AMD EPYC 9654、约 1 TiB 内存、Ubuntu 22.04 / Linux 5.15.0-191。

最终结论：9B 仍具有最高绝对吞吐；35B D 组短测达到 180.64 tok/s 聚合吞吐，并在 C16 同时超过对照 TPS 与 TTFT，但尚不能替代原正式结论。30B 和 80B 在 C16 超过对照；35B 与 80B 的最新候选均需补跑正式测试。

数据路径：
/data/infra/benchmarks/gr308-35b-mtp4-short-matrix-ready-20260915/
/data/infra/benchmarks/gr308-35b-two-card-tps-20260915/
/data/infra/benchmarks/gr308-final-high-throughput-20260915/
/data/infra/benchmarks/gr308-80b-short-tuning-20260915/

报告依据：服务器原生 benchmark.json、result.json、launch.json、server.log 与 FANTASY SMI 输出；整理日期 2026-09-15。