性能测试数据研究报告

风华 GR308 Qwen 系列并发性能测试与调优报告

vLLM 0.18.0 | BF16 | C1 / C16 / C32 | MTP、CUDA Graph、KV、MoE backend 与 EP 消融 | 最终选定方案

测试对象：Qwen3.6-35B-A3B、Qwen3.5-9B、Qwen3-30B-A3B、Qwen3-Next-80B-A3B-Instruct。

平台：4 张 GR308 物理卡 / 8 个逻辑设备；双路 AMD EPYC 9654；约 1 TiB 内存；驱动 1.1.0.19。

负载：35B/9B/30B 输入输出 3072/1024；80B 为 1024/1024；temperature=0、ignore-eos、request-rate=inf。

C32 单卡最高吞吐	C32 最高总吞吐	最高屋顶效率
320.90 tok/s Qwen3-30B-A3B	339.26 tok/s 80B / 2 张物理卡	40.1% 30B / C32

一、结论摘要

结论 1 | 30B 是当前单卡高并发首选。纯 TP2、不开 EP、auto MoE、batch4096、async 在 C32 达到 320.90 tok/s，占理想批处理屋顶 40.1%。

结论 2 | 9B 的双 TP1/DP2 是最大结构性收益。C32 达 287.02 tok/s，比 C16 提高 16.1%；但 TTFT 升至 8.81 s，因此 C16 是平衡档，C32 是吞吐档。

结论 3 | 35B 在当前软件栈下已接近参数调优上限。MTP4 + batch4096 的 C16/C32 为 180.64/208.08 tok/s；Graph128、batch6144、Triton grouped GEMM 与 EP2 均未带来足够收益。

结论 4 | 80B 的主要收益来自 MTP。TP4 + MTP3 在 C32 达 339.26 tok/s，比 C16 提高 32.6%；TP4+EP4 的 C16 反而下降 8.6%。

结论 5 | 当前 EP 不建议进入生产配置。30B/35B 的 EP2 和 80B 的 EP4 均回归；80B TP2×DP2×EP2 在 profile 阶段遇到固件信号量超时。

统一约束：所有有效结果均保持 custom all-reduce 开启，不使用 `--disable-custom-all-reduce`。

二、测试口径、证据等级与可比性

项目	定义	报告用法
Decode Avg TPS	1000 / mean TPOT(ms)，单请求平均解码速率	与外部对照表同口径
聚合输出吞吐	整个服务实例的 output tokens/s	高并发容量排序与屋顶比较
Median TTFT	请求到首 token 的中位时间	评估吞吐换延迟的代价
正式测试	C1/C16 各 64 requests，failed=0	9B、30B 最终 C1/C16
短测	C1 通常 16、C16 通常 32、C32 为 64 requests	参数筛选；不声称统计显著性

外部对照的可比性：35B 拓扑与负载一致；9B 的选定方案由 TP2 改为双 TP1/DP2；30B 由 EP+TP2 改为纯 TP2；80B 输入/输出和 TP4 一致。因此对照用于工程方案评估，不是严格的单变量实验。

模型	并发	TTFT 选定	TTFT 对照	TTFT 变化	Decode 选定	Decode 对照	TPS 变化	聚合吞吐
Qwen3.6-35B-A3B	C1	1537.19	1731.87	-11.2%	50.75	52.91	-4.1%	47.21
	C16	3321.47	3487.11	-4.7%	13.93	12.74	+9.4%	180.64
Qwen3.5-9B	C1	2335.93	1545.07	+51.2%	54.64	45.09	+21.2%	48.62
	C16	3501.62	2487.47	+40.8%	18.90	11.97	+57.9%	247.16
Qwen3-30B-A3B	C1	1054.43	1245.71	-15.4%	26.43	26.85	-1.5%	25.76
	C16	4225.69	3384.84	+24.8%	15.22	11.70	+30.1%	225.67
Qwen3-Next-80B-A3B	C1	607.98	1072.45	-43.3%	48.52	33.23	+46.0%	47.13
	C16	3535.56	6048.71	-41.5%	19.71	15.02	+31.2%	255.93

方向说明：TTFT 负变化为改善，Decode TPS 正变化为改善。9B 与 30B 是吞吐优先方案，因此接受了部分 TTFT 代价。

三、对照图表与 C32 扩展结果

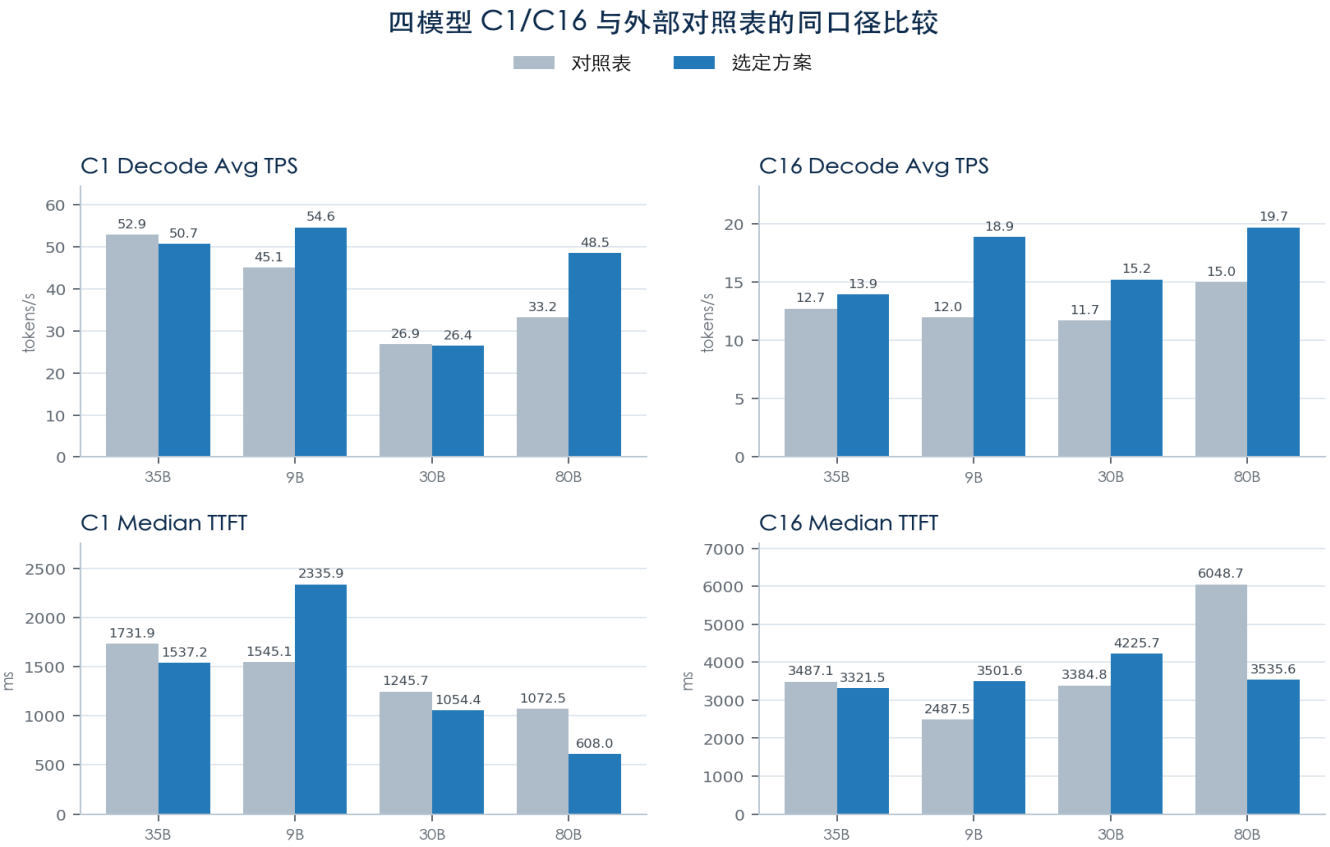


图 1：同并发口径下的 Decode Avg TPS 和 Median TTFT。不同模型的输入长度与卡数不同，不以绝对数值直接推导模型优劣。

模型	C16 聚合	C32 聚合	扩展收益	C32 TTFT	C32 Decode	完成/失败
Qwen3.6-35B-A3B	180.64	208.08	+15.2%	4909.15	8.20	64/0
Qwen3.5-9B	247.16	287.02	+16.1%	8806.52	12.62	64/0
Qwen3-30B-A3B	225.67	320.90	+42.2%	5616.56	11.33	64/0
Qwen3-Next-80B-A3B	255.93	339.26	+32.6%	4141.24	13.74	64/0

C32 适合容量规划，但不应替代 C16 延迟评估。9B 的 C32 TTFT 增至 8.81 s，而 80B 在吞吐 +32.6% 时 TTFT 仅较 C16 增加约 17.1%，扩展更理想。

四、Qwen3.5-9B 调优矩阵

组别	关键变量	C1 聚合	C16 聚合	C32 聚合	判断
A	MTP3 / G4-32 / b2048 / 8GiB	59.40	231.81	-	MTP3 基线
B	MTP3 / G4-64 / b2048 / 8GiB	58.97	215.79	-	Graph64 回归
C	MTP3 / G4-32 / b4096 / 8GiB	60.35	237.14	-	batch4096 有效
D	MTP3 / G4-32 / b4096 / auto KV	59.99	239.27	-	自动 KV 小幅提升
E2	MTP2 / G4-32 / b4096 / auto KV	49.73	228.41	-	MTP2 不选
E4	MTP4 / G4-32 / b4096 / auto KV	66.29	234.94	-	C1 有利
F1	单 TP1 / MTP4	49.66	157.67	-	单副本容量不足
F2	dual TP1 / DP2 / MTP4	49.69	247.87	-	最大结构性收益
Final	dual TP1 / DP2 / MTP4，正式 C1/C16	48.62	247.16	287.02	最终选定

主要因果链：MTP3 相比初始 MTP1 提升解码路径；batch2048→4096 进一步提高 C16；自动 KV 主要改善容量余量；最大收益来自将一张物理卡的两个逻辑设备变为双 TP1/DP2 副本。

失败与修正：首次 C32 在 DP2 下将 max-num-seqs=32 应用到每个副本，不均匀调度触发 Fantasy SSM 的 ssm_state_indices 非连续布局错误。将每副本上限修正为 16 后，C32 64/64 请求完成。

最终判断：C16 是交互与吞吐的平衡档，C32 仅用于吞吐优先队列。继续扩大 Graph 的预期收益很小，后续应优先比较内置 DP2 与外部双端口轮询。

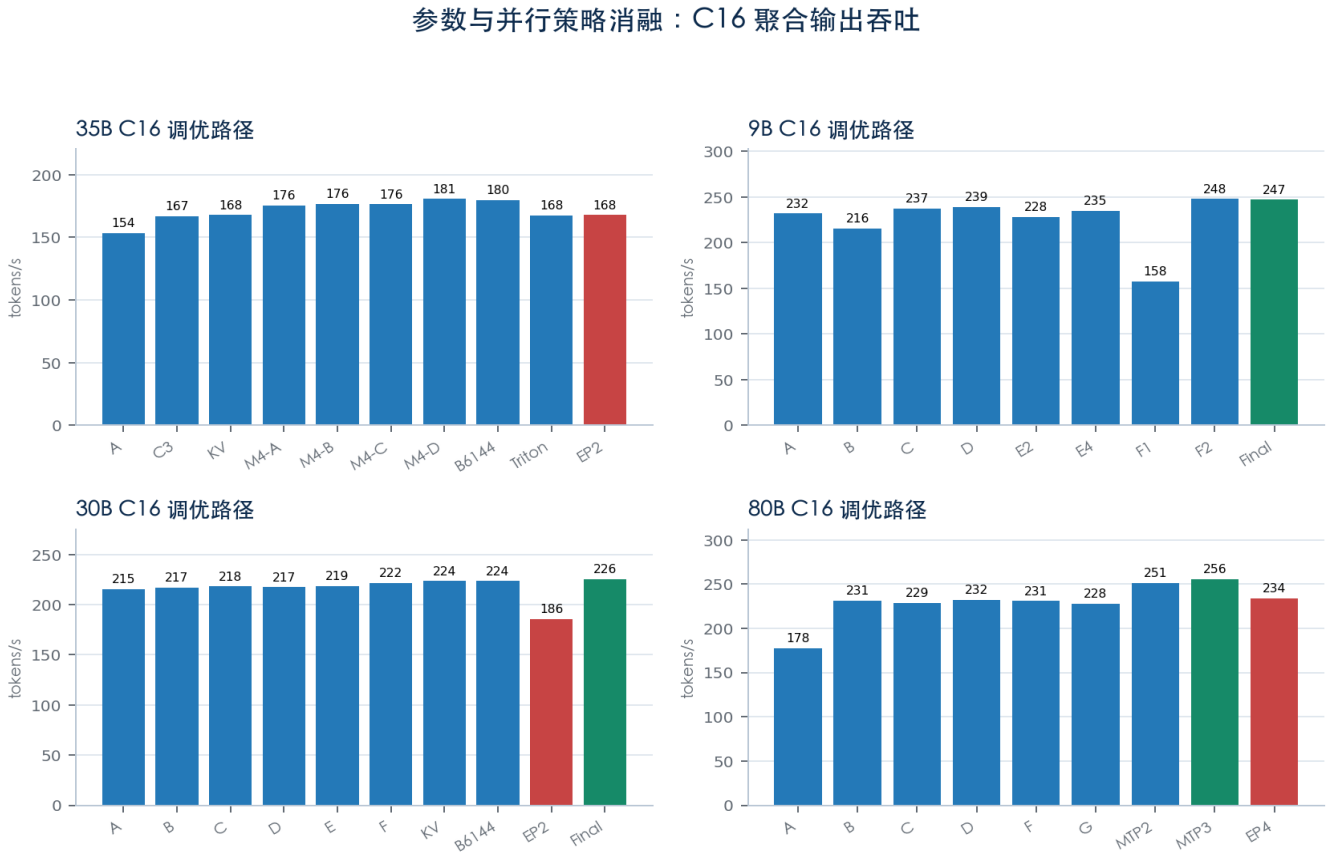


图 2：四模型主要调优组的 C16 聚合输出吞吐。绿色为最终选定，红色为 EP 或后端回归组。

五、Qwen3-30B-A3B 调优矩阵

组别	关键变量	C1 聚合	C16 聚合	C32 聚合	判断
A	G32 / auto / b2048 / block800	10.88	215.33	-	基线
B	G4-32 / auto / b2048	24.39	216.77	-	Graph 覆盖有效
C	G4-32 / Triton / b2048	23.44	218.10	321.35	C32 +0.14%，持平
D	auto / block1088 / b2048	23.46	217.38	-	block1088 无收益
E	auto / block800 / b4096 / sync	26.10	218.80	-	batch4096 有效
F	auto / block800 / b4096 / async	25.52	221.52	-	async 小幅提升
KV	auto KV	-	223.50	319.80	无稳定收益
B6144	b6144 / 8GiB / async	-	223.54	321.10	吞吐微增，TTFT 恶化
EP2	TP2 + EP2 / linear	-	185.86	230.52	明显回归
Final	auto / b4096 / block800 / 8GiB / async	25.76	225.67	320.90	最终选定

有效路径：Graph 由单一 32 扩为 4/8/16/32 显著改善 C1 图命中；batch4096 提升 C16；async 在当前负载下进一步提升聚合吞吐。

未采用路径：block800→1088 基本无收益；自动 KV 的 C16/C32 方向不一致；batch6144 仅小幅提吞吐但 TTFT 显著增加；Triton grouped GEMM 的 C32 仅比 auto 高 0.14%，低于 3% 采用阈值。

EP2 结论：C16/C32 回落至 185.86/230.52 tok/s，比选定方案低约 17.6%/28.2%。当前专家 dispatch/combine、all-to-all 和同步开销高于专家计算节省。

最终判断：保留 auto MoE backend、block800、batch4096、8 GiB KV 和 async。C32 的 320.90 tok/s 是四个模型中最高的单物理卡吞吐。

六、Qwen3.6-35B-A3B 调优矩阵

组别	关键变量	C1 聚合	C16 聚合	C32 聚合	判断
A	MTP1 / G32 / b2048	16.99	153.53	-	早期基线
C3	MTP3 / G4-64 / b2048 / 8GiB	43.56	167.06	-	MTP3 有效
KV	MTP3 / b4096 / auto KV	44.12	167.73	-	自动 KV 恢复容量
M4-A	MTP4 / G4-64 / b2048	46.70	175.57	-	MTP4 关键收益
M4-B	MTP4 / G4-128 / b2048	46.73	176.49	-	Graph128 收益不足
M4-C	MTP4 / G4-64 / b3072	46.71	176.41	-	中间档
M4-D	MTP4 / G4-64 / b4096	47.21	180.64	208.08	最终选定
B6144	MTP4 / b6144	-	179.72	209.08	C32 +0.48%，不足采用
Triton	grouped GEMM + 融合	-	167.69	188.63	明显回归
EP2	TP2 + EP2 / linear	-	167.81	185.50	明显回归

关键收益：MTP1→MTP3 建立基础增益，MTP3→MTP4 在同为 batch2048 时将 C16 从 164.38 提高至 175.57 tok/s；MTP4 下 batch2048→4096 再提高至 180.64 tok/s，同时降低 TTFT。

边际收益已收敛：Graph128 相对 Graph64 的 C16 只有约 0.5% 差异；batch6144 在 C32 只高 0.48%，同时 C16 下降且 TTFT 增加，因此不改变决策。

MoE/EP 路径：Triton grouped GEMM + 专家融合回落至 167.69/188.63 tok/s；EP2 linear 为 167.81/185.50 tok/s。round-robin 专家放置在当前插件中未得到真正支持，无法构成有效 A/B。

最终判断：在当前后端版本中，继续调 batch/Graph 的预期收益低于 3%。要获得两位数改善，需要原生融合 token sorting、grouped GEMM、expert combine 和 MTP verify kernel。

七、Qwen3-Next-80B-A3B-Instruct 调优矩阵

组别	关键变量	C1 聚合	C16 聚合	C32 聚合	判断
A	eager / no MTP / 8GiB	10.76	177.71	-	基线
B	eager / MTP1 / 8GiB	25.91	231.30	-	MTP1 主要收益
C	MTP1 / Graph32	28.47	228.68	-	C1 改善
D	MTP1 / Graph64 / b2048	28.41	231.98	-	MTP1 吞吐最优
F	MTP1 / Graph64 / b4096	28.19	230.99	-	TTFT 档
G	MTP1 / b4096 / async	28.43	228.07	-	async 回归
MTP2	TP4 / MTP2 / Graph64	36.75	251.49	-	明确正收益
MTP3	TP4 / MTP3 / Graph64	47.13	255.93	339.26	最终选定
EP4	TP4 + EP4 / MTP3	46.99	233.93	-	C16 -8.6%
TP2xEP2	TP2 x DP2 x EP2	-	-	-	profile 固件信号量超时

MTP 是决定性因素：无 MTP→MTP1 将 C16 从 177.71 提高至 231.30 tok/s；MTP2 进一步提高至 251.49；MTP3 达 255.93 tok/s，且 C1 达 47.13 tok/s。

Graph/KV/调度：Graph32/64 主要改善 C1 和小批命中；batch4096 可作 MTP1 的低 TTFT 档，但不是吞吐最优；async 会降低 C16 并明显恶化 TTFT；自动 KV 在初始化阶段失败，最终保留 8 GiB。

EP 结果：TP4+EP4 可完成测试，但 C16 仅 233.93 tok/s，比 TP4/MTP3 低 8.6%，TTFT 增加约 21.2%。TP2×DP2×EP2 在修正 DP 设备类型后越过原始错误，但 profile run 仍触发 Fantasy firmware semaphore 超时。

最终判断：TP4/MTP3 为高吞吐首选。C32 达 339.26 tok/s，但占用两张物理卡，折合 169.63 tok/s/卡。

八、理论屋顶、资源效率与瓶颈

C1：单请求解码效率

模型	C1 理论屋顶	C1 聚合	C1 Decode	系统屋顶效率	纯 Decode 效率
Qwen3.6-35B-A3B	336	47.21	50.75	14.1%	15.1%
Qwen3.5-9B	56	48.62	54.64	86.8%	97.6%
Qwen3-30B-A3B	305	25.76	26.43	8.4%	8.7%
Qwen3-Next-80B-A3B	672	47.13	48.52	7.0%	7.2%

C16/C32：高并发吞吐效率

模型	理想批处理屋顶	C16 聚合	C16 效率	C32 聚合	C32 效率	C32 每卡
Qwen3.6-35B-A3B	1066	180.64	16.9%	208.08	19.5%	208.08
Qwen3.5-9B	896	247.16	27.6%	287.02	32.0%	287.02
Qwen3-30B-A3B	800	225.67	28.2%	320.90	40.1%	320.90
Qwen3-Next-80B-A3B	1420	255.93	18.0%	339.26	23.9%	169.63

实测吞吐 / 理论屋顶

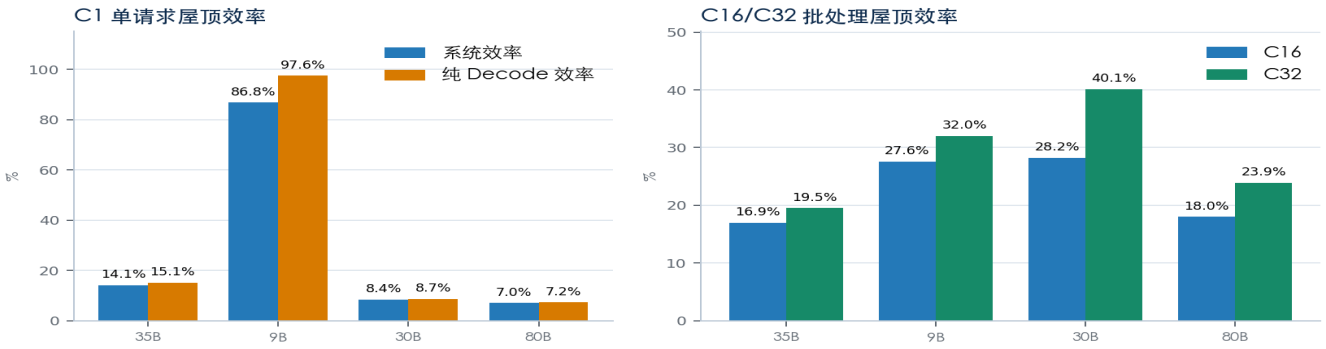


图 3：C1 同时展示端到端聚合输出效率和纯 Decode 效率；C16/C32 使用整卡理想批处理屋顶。屋顶值是规划估算，不是硬件计数器利用率。

模型	主要瓶颈	已验证的优化	下一阶段高收益方向
9B	DP 副本负载均衡、prefill/decode 队列气泡	双 TP1/DP2、MTP4	外部双端口轮询与 NUMA 绑定
30B	专家小 GEMM、路由后调度	纯 TP2、batch4096、async	原生 grouped GEMM + dispatch/combine 融合
35B	MoE kernel、MTP verify、专家 token 分布	MTP4、batch4096	token sorting + grouped GEMM + expert combine 后端融合
80B	跨卡 TP 通信、线性注意力、调度开销	MTP3、Graph64	DP/EP 设备适配、固件同步、MTP verify 优化

总体判断：30B 在 C32 的理想屋顶效率最高；80B 虽有最高聚合吞吐，但每卡吞吐低于 9B/30B/35B。35B/80B 的下一轮显著提升需要后端或固件级工作，而不是继续扩大 batch/Graph。

九、最终选定方案与测试结果

模型	物理卡	最终配置	证据
Qwen3.6-35B-A3B	1	TP2 / MTP4 / Graph 4-64 / batch4096 / block1088 / auto KV / sync / auto MoE / no EP	short
Qwen3.5-9B	1	dual TP1 / DP2 / MTP4 / Graph 4-32 / batch4096 / block800 / auto KV / sync	formal C1/C16; short C32
Qwen3-30B-A3B	1	TP2 / no EP / auto MoE / Graph 4-32 / batch4096 / block800 / 8 GiB KV / async	formal C1/C16; short C32
Qwen3-Next-80B-A3B	2	TP4 / MTP3 / Graph 4-64 / batch2048 / block1088 / 8 GiB KV / sync / no EP	short

模型	并发	Median TTFT(ms)	Decode Avg TPS	聚合输出 TPS	完成/失败	定位
Qwen3.6-35B-A3B	C1	1537.19	50.75	47.21	16/0	单请求
	C16	3321.47	13.93	180.64	32/0	平衡吞吐
	C32	4909.15	8.20	208.08	64/0	峰值吞吐
Qwen3.5-9B	C1	2335.93	54.64	48.62	64/0	单请求
	C16	3501.62	18.90	247.16	64/0	平衡吞吐
	C32	8806.52	12.62	287.02	64/0	峰值吞吐
Qwen3-30B-A3B	C1	1054.43	26.43	25.76	64/0	单请求
	C16	4225.69	15.22	225.67	64/0	平衡吞吐
	C32	5616.56	11.33	320.90	64/0	峰值吞吐
Qwen3-Next-80B-A3B	C1	607.98	48.52	47.13	16/0	单请求
	C16	3535.56	19.71	255.93	32/0	平衡吞吐
	C32	4141.24	13.74	339.26	64/0	峰值吞吐

高并发容量与资源归一化

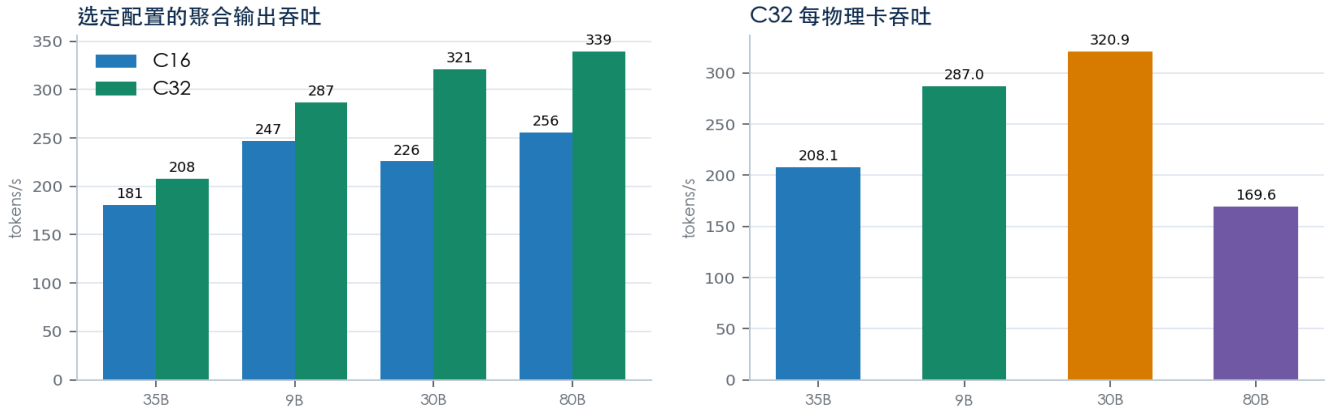
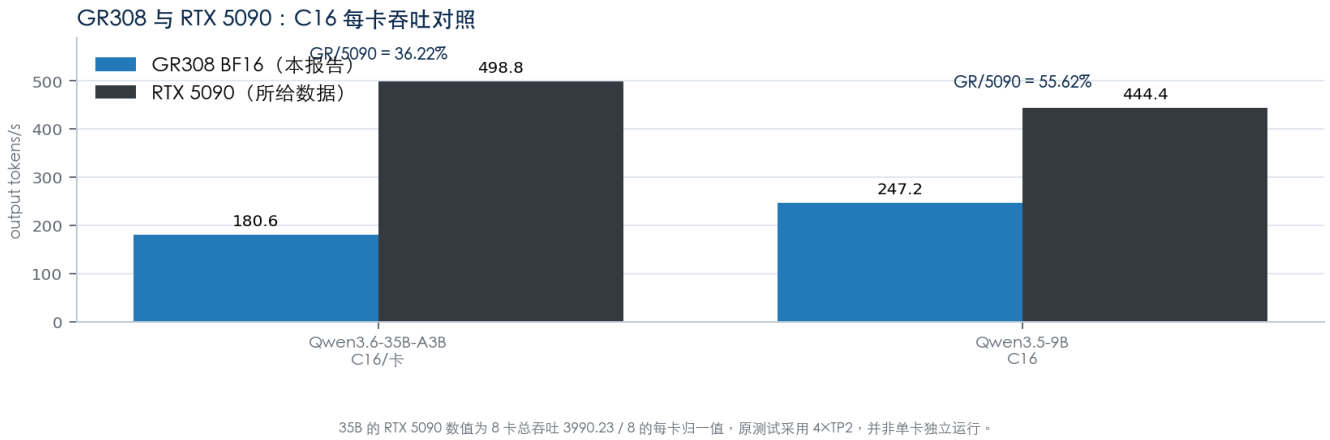


图 4：最终配置在 C16/C32 下的聚合输出吞吐及 C32 每物理卡归一化值。

最终选型：若以单卡吞吐与成本为主，优先 30B，其次 9B；若必须使用 35B，保留 MTP4 且不开 EP；若以最大模型能力为主，选 80B TP4/MTP3，但应按两卡成本评估。

十、与 RTX 5090 的吞吐对比

本节仅保留截图中提供的 Qwen3.6-35B-A3B 与 Qwen3.5-9B 两组数据，统一以 C16 每卡吞吐展示。35B 的 RTX 5090 值是 8 卡总吞吐的每卡归一值，不代表单张 5090 脱离 TP2 后可独立复现。



35B 的 RTX 5090 数值为 8 卡总吞吐 3990.23 / 8 的每卡归一值，原测试采用 4×TP2，并非单卡独立运行。

图 5：GR308 与 RTX 5090 的 C16 每卡吞吐。35B 使用每卡归一值；9B 为单卡同并发数据。

数据对照与有效性

模型	并发	GR308 单卡吞吐	RTX 5090 每卡吞吐	GR/5090	数据有效性
Qwen3.6-35B-A3B	C16/卡	180.64	498.78	36.22%	RTX 5090 数值由图中 8 卡总吞吐 3990.23 除以 8；实际采用 4×TP2，不是单卡独立运行
Qwen3.5-9B	C16	247.16	444.40	55.62%	同模型、BF16、单卡、C16；但 RTX 5090 使用 ShareGPT / 最大输出 256，GR308 使用固定 3072/1024

Qwen3.6-35B-A3B：GR308 为 180.64 tok/s；RTX 5090 每卡归一值为 3990.23 ÷ 8 = 498.78 tok/s；GR/5090 为 36.22%。原 5090 测试采用 4×TP2，因此这个比例适合做八卡系统的每卡产出参考，不适合解释为两种 GPU 的独立单卡性能比。

Qwen3.5-9B：GR308 为 247.16 tok/s；RTX 5090 为 444.40 tok/s；GR/5090 为 55.62%。两者均为 BF16、单卡、C16，但 5090 使用 ShareGPT、最大输出 256，GR308 使用固定输入/输出 3072/1024，因此仍存在负载差异。

结论：在当前对照中，9B 的数据可比性明显高于 35B。35B 应标注为“多卡结果的每卡归一比较”；若用于采购或部署判断，还需在单张 RTX 5090 上使用同一权重、同一 C16 负载和相同输入/输出长度复测。

5090 数据来源：用户提供的对照截图；35B 原始总吞吐 3990.23 tok/s（8 张 RTX 5090，4×TP2），9B 单卡 C16 吞吐 444.40 tok/s。

十一、运行边界、异常、验收条件与证据索引

运行边界：精度均为 BF16；max model length=4096；关闭 prefix caching；默认同步调度，仅 30B 最终选 async；custom all-reduce 始终保持开启。

已知异常：并发初始化多个 FHCCL/RCCL communicator 时曾出现通信初始化失败，改为上一服务 API ready 后再启动下一通信域后消失。80B 自动 KV 初始化失败；35B C64 和 9B 首次 C32 触发 Fantasy SSM 的非连续索引问题。

硬件状态：各轮测试后 8 个逻辑设备健康状态为 OK，最终测试后显存回落至约 540 MiB/逻辑设备。

统计限制：参数矩阵主要是单轮短测，没有 3 轮以上的配对重复、标准差或置信区间。本报告只做描述性工程判断；小于 3% 的差异视为基本持平，不宣称统计显著。

上线前验收：35B MTP4 和 80B MTP3 应在固定 seed、物理卡、CPU NUMA 亲和性和启动顺序后各执行至少 3 轮 64-request 复测；报告跨轮变异系数，并确认请求均完整输出 1024 tokens、failed=0。

主要远端数据路径：

/data/infra/benchmarks/gr308-adaptive-short-matrix-20260915/
/data/infra/benchmarks/gr308-final-high-throughput-20260915/
/data/infra/benchmarks/gr308-35b-mtp4-short-matrix-ready-20260915/
/data/infra/benchmarks/gr308-80b-short-tuning-20260915/
/data/infra/benchmarks/gr308-moe-c32-ep-short-20260917-attempt4/
/data/infra/benchmarks/gr308-final-c16-c32-last-mile-20260917/
/data/infra/benchmarks/gr308-final-35b-c32-recheck-20260917/
/data/infra/benchmarks/gr308-35b-30b-native-ep2-20260917/
/data/infra/benchmarks/gr308-80b-tp4-ep4-20260917/
/data/infra/benchmarks/gr308-9b-80b-c32-short-20260917/
/data/infra/benchmarks/gr308-9b-c32-retry-20260917/

报告结论：本轮参数调优已基本收敛。当前最具部署性价比的是 30B 和 9B；35B 与 80B 已证明 MTP 的明确价值，但若要继续显著提升，需转向 MoE/MTP 内核、跨卡通信与固件同步层。

数据来源：服务器原生 benchmark.json、result.json、launch.json、server.log 和 FANTASY SMI 状态；整理日期 2026-09-17。