风华 GR308 Qwen 系列性能优化思路

版本：2026-09-16

适用环境：GR308、vLLM 0.18.0、vllm_fant 1.1.0.20、BF16

覆盖模型：Qwen3.6-35B-A3B、Qwen3.5-9B、Qwen3-30B-A3B、Qwen3-Next-80B-A3B-Instruct

1. 文档目标

本文档整理当前四个 Qwen 模型在 GR308 上的已验证配置、仍待确认的候选配置，以及下一阶段以高吞吐为主的优化路线。文档重点不是继续无边界地扩大参数矩阵，而是优先验证高概率方向，并用统一口径判断优化是否真实有效。

当前约束如下：

- 精度固定为 BF16。
- 自定义 all-reduce 必须保持启用，所有命令均不得加入 --disable-custom-all-reduce。
- 默认关闭 prefix caching，避免缓存命中干扰性能比较。
- 服务最大上下文长度为 4096，最大序列数为 16。
- 35B、9B、30B 使用 3072 输入、1024 输出；80B 使用 1024 输入、1024 输出。
- 短测中 C1 使用 16 prompts、C16 使用 32 prompts；正式测试中 C1/C16 均使用 64 prompts。
- 每次只改变一个主要变量；跨卡重复、完整输出和硬件清理结果必须一并记录。

2. 当前结果与配置基线

模型	当前配置	C1 TTFT	C1 Decode TPS	C16 TTFT	C16 Decode TPS	C16 聚合吞吐	结果性质
Qwen3.6-35B-A3B	TP2 / MTP4 / Graph 4–64 / batch 4096 / 自动 KV / block 1088 / 同步	1537.19 ms	50.75	3321.47 ms	13.93	180.64 tok/s	短测候选
Qwen3.5-9B	TP1 + DP2 / MTP4 / Graph 4–32 / batch 4096 / 自动 KV / block 800 / 同步	2335.93 ms	54.64	3501.62 ms	18.90	247.16 tok/s	正式结果
Qwen3-30B-A3B	TP2 / 无 MTP / 无 EP / Graph 4–32 / batch 4096 / 固定 8 GiB KV / block 800 / async	1054.43 ms	26.43	4225.69 ms	15.22	225.67 tok/s	正式结果
Qwen3-Next-80B-A3B-Instruct	TP4 / MTP1 / Graph 4–64 / batch 2048 / 固定 8 GiB KV / block 1088 / 同步	595.37 ms	28.86	3528.79 ms	16.20	231.98 tok/s	短测候选

结果解释：

- 9B 是当前绝对吞吐最高的配置，主要收益来自双 TP1 / DP2、MTP4 和自动 KV。
- 30B 在不开 EP 的情况下获得更稳定的 C16 吞吐；现有软件栈下，EP 尚未证明能够稳定带来收益。
- 35B 的 MTP4 / batch4096 组合首次同时超过对照表的 C16 Decode TPS 和 TTFT，但仍需正式复测。
- 80B 的主要收益来自 MTP1；Graph64 对 C16 Decode TPS 有进一步增益，自动 KV 则在本轮启动失败。

3. 统一优化方法

3.1 优化目标排序

本轮以高吞吐为第一目标，指标优先级为：

1. C16 Decode Avg TPS。
2. C16 聚合输出吞吐。
3. 请求完整率和运行稳定性。
4. Median TTFT。
5. C1 Decode Avg TPS。

如果多个配置的 C16 Decode TPS 差距不超过 3%，优先选择 TTFT
更低、跨卡方差更小、启动与清理更稳定的配置，而不是机械选择单次最高值。

3.2 测试分层

每个新方向按三层推进：

1. 微型准入：启动、warm-up、短输出正确性、Graph 捕获、MTP 接受率和显存检查。
2. 短测筛选：C1 16 prompts、C16 32 prompts，用于快速排除负收益方向。

3. 正式确认：C1/C16 各 64 prompts，至少跨两张物理卡重复；最终候选建议再执行 3 个固定 seed。

只有正式确认结果才能作为部署结论。短测只用于排序候选，不能替代验收。

3.3 每轮必须记录的证据

- 完整 vllm serve 启动参数和镜像 digest。
- 模型目录、权重身份、MTP 配置及实际接受率。
- Graph capture sizes、Graph 捕获和回放计数。
- C1/C16 的 TTFT、TPOT、ITL、Decode Avg TPS、聚合吞吐。
- completed、failed 和每条请求的实际输出长度。
- 启动前后显存、温度、核心健康以及容器清理状态。
- 物理卡编号、逻辑设备编号、CPU 亲和性和运行 seed。

4. Qwen3.6-35B-A3B 优化路线

4.1 首要任务：确认 D 组是否可复现

当前最优 D 组为 MTP4、Graph [4,8,16,32,64]、batch4096、自动 KV、block1088。它比此前正式配置的 C16 Decode TPS 和聚合吞吐更高，但样本量较小，因此第一优先级不是继续增加新参数，而是完成以下确认：

- 在至少两张不同物理卡上各重复一次短测。
- 完成 C1/C16 各 64 prompts 的正式测试。
- 对比 MTP 接受率、平均接受长度和 Graph 命中率，确认收益来自 MTP4，而不是单次运行波动。
- 检查 C16 TTFT 和吞吐是否能同时保持，不接受以大量失败或输出不足换取的表面 TPS。

4.2 后续高概率方向

1. MTP 深度和接受率联合优化

在同一 Graph、batch 和 KV 配置下，对 MTP3、MTP4 做正式 A/B。MTP4 已显示较高 Decode TPS，但还应结合 draft acceptance 和每步验证成本判断。若 MTP4 接受率波动大，可测试 MTP3 与 MTP4 的业务分档，而不是只保留单一配置。

2. Graph 桶精简

对比 [4,8,16,32,64]、[1,2,4,8,16,32,64] 和 [4,8,16,32,64,128]。目标是确认小 batch 桶是否改善 C1，以及 128 桶是否对 C16 有收益。若无收益，应使用更小的捕获集合以减少启动时间和显存开销。

3. Batched tokens 局部搜索

以 4096 为中心测试 3072、4096、6144。此前 2048、3072、4096 的结果表明该参数对 TTFT 和吞吐均有影响，但不是单调关系。任何更大值必须先通过显存和完整输出准入。

4. 自动 KV 与固定 KV 对照

35B 的自动 KV 已成功运行，建议正式比较自动 KV 与固定 8 GiB，记录实际可用 block 数、峰值显存和 C16 驻留能力。自动 KV 若稳定，应优先于人为限制 8 GiB。

5. 跨卡拓扑和 CPU 亲和性

当前结果存在明显的卡间和启动时序影响。应固定 CPU NUMA、错峰初始化 FHCCL/RCCL communicator，并在同一配置下做跨卡重复，避免把拓扑差异误判为参数收益。

4.3 不建议继续投入的方向

- block800 已出现启动失败，35B 暂时固定 block1088。
- async scheduling 没有显示出稳定优势，高吞吐候选继续使用同步调度。
- fuse_gemm_comms、fuse_allreduce_rms 相关候选曾启动失败，不应在缺少后端兼容证据时直接加入正式配置。
- 不以禁用 custom all-reduce 作为规避故障手段。

5. Qwen3.5-9B 优化路线

5.1 当前判断

双 TP1 / DP2、MTP4、Graph [4,8,16,32]、batch4096、自动 KV 是当前高吞吐最优方案。其 C16 Decode TPS 和聚合吞吐均为四个模型最高，但 TTFT 高于 TP2 对照，因此应把吞吐档和低延迟档分开维护。

5.2 后续方向

1. DP2 负载均衡验证

分别统计两个 TP1 replica 的请求数、队列时间、输出吞吐和尾延迟，确认 247.16 tok/s 不是短时间调度偏差。必要时显式使用两个端口和外部轮询，与 vLLM 内部 DP2 做对照。

2. 单 replica 并发配比

在总并发 16 下测试每个 replica 的 8+8、6+10 等分配，观察是否存在单实例最优并发点。若 8+8 最稳，应将其固化为服务层并发上限。

3. MTP3/MTP4 正式对照

MTP4 当前吞吐最好，但应补充接受率、拒绝率及 draft 开销。若低并发业务更看重 TTFT，可保留 MTP3 或 TP2 作为低延迟档。

4. Graph32/64 对照

当前 Graph32 已表现良好。Graph64 只需进行一次隔离短测；若 C16 收益不足 3%，不扩大正式矩阵。

5. 自动 KV 稳定性

连续冷启动三次，记录自动分配的 KV block 数及显存余量。Qwen3.5 属于混合状态模型，不能只依据通用 Transformer 的 KV 估算判断容量。

6. Qwen3-30B-A3B 优化路线

6.1 当前判断

该模型没有原生 MTP 权重。当前最佳方案是 TP2、不开 EP、Graph [4,8,16,32]、batch4096、固定 8 GiB KV、block800、async scheduling。其 C16 Decode TPS 比对照明显提升，但 TTFT 增加，属于吞吐优先配置。

6.2 后续方向

1. Async 调度边界

对 C4、C8、C16 分别比较同步和异步调度，确定 async 从哪个并发开始产生净收益。若只在 C16 有收益，应按业务并发动态选择服务档位。

2. MoE backend 对照

在其他参数不变时比较默认 auto 与 Triton backend，重点记录 expert routing、kernel 时间和启动稳定性。若 Triton 收益不足 3% 或出现回归，保持 auto。

3. Batch 4096 周边搜索

测试 3072、4096、6144，观察 C16 Decode TPS 与 TTFT 的拐点。固定 8 GiB KV，避免同时改变 KV 容量造成混淆。

4. Graph64 单变量验证

当前 Graph32 为稳定基线。只追加一次 Graph64 短测；若没有稳定吞吐增益，不进入正式复测。

5. EP 作为独立兼容性课题

EP 在当前软件栈下未稳定运行，不纳入近期高吞吐主线。只有在 FHCCL/RCCL 初始化、专家 all-to-all 和内存布局问题得到独立解决后，才重新比较 EP+TP2 与纯 TP2。

7. Qwen3-Next-80B-A3B-Instruct 优化路线

7.1 首要任务：正式确认 Graph64 候选

当前高吞吐候选为 TP4、MTP1、Graph [4,8,16,32,64]、batch2048、固定 8 GiB KV、block1088。短测中 C16 Decode TPS 为 16.20，TTFT 为 3528.79 ms。应优先补齐跨两组物理卡和 64+64 prompts 的正式测试。

7.2 后续方向

1. MTP1 接受率诊断

MTP1 是 80B 的主要增益来源。正式测试需要记录每轮 draft、accepted tokens 和拒绝比例，确认长时间运行后接受率不会衰减。

2. Graph32/64/128

Graph32 与 Graph64 的差距较小，但 C16 以 Graph64 更好。可追加 Graph128 单变量短测；若收益不足 3% 或启动显存明显增加，则保留 Graph64。

3. 吞吐档与 TTFT 档分离

batch2048 的 C16 Decode TPS 为 16.20；batch4096 的 C16 Decode TPS 为 16.02，但 TTFT 从约 3529 ms 降至约 2975 ms。建议保留两套配置：batch2048 用于高吞吐，batch4096 用于较低首包延迟。

4. 固定 KV 容量搜索

自动 KV 已在初始化阶段失败，不应直接用于正式部署。可在固定模式下测试 8、10、12 GiB，逐级验证启动、C16 完整率和显存余量；每次只调整 KV 容量。

5. TP4 拓扑绑定

80B 跨两张物理卡，应固定相邻逻辑设备、CPU NUMA 和 communicator 启动顺序。需要把拓扑变化作为独立变量，而不是与 MTP、Graph 同时调整。

8. 下一阶段建议短测矩阵

优先级	模型	变量	候选	其他参数	目的
P0	35B	重复性	D 组跨两卡重复	MTP4 / G4–64 / b4096 / 自动 KV	确认当前最优不是卡间波动
P0	35B	正式样本	C1/C16 各 64 prompts	保持 D 组	形成可部署结论
P0	80B	正式样本	C1/C16 各 64 prompts	MTP1 / G4–64 / b2048 / 8 GiB	确认短测结果
P1	35B	MTP	3、4	G4–64 / b4096 / 自动 KV	验证接受率与验证开销
P1	9B	DP 调度	内部 DP2、双端口双 TP1	MTP4 / G4–32 / b4096	判断负载均衡效率
P1	30B	调度	sync、async	G4–32 / b4096 / 8 GiB	找到并发收益边界
P1	80B	服务档位	b2048、b4096	MTP1 / G4–64 / 8 GiB	吞吐与 TTFT 分档
P2	35B	Graph	G1–64、G4–64、G4–128	MTP4 / b4096	精简 Graph 桶
P2	30B	batch	3072、4096、6144	auto backend / async	搜索 C16 吞吐拐点
P2	80B	固定 KV	8、10、12 GiB	MTP1 / G4–64 / b2048	提高并发驻留能力

9. 四卡资源编排建议

四张物理卡共八个逻辑设备。35B、9B、30B 各占一张物理卡，80B 占两张物理卡，因此四个模型无法在当前最优拓扑下同时运行。

建议分两波执行：

第一波：三模型并行筛选

- 物理卡 0（逻辑 0、1）：35B。
- 物理卡 1（逻辑 2、3）：9B。
- 物理卡 2（逻辑 4、5）：30B。
- 物理卡 3（逻辑 6、7）：保留给 35B 跨卡重复或故障隔离。

服务启动必须错峰。只有前一个模型的 API 和 EngineCore 真正 ready 后，才启动下一个模型，避免多个 FHCCL/RCCL communicator 同时初始化。

第二波：80B 独占两卡

- 物理卡 2、3（逻辑 4–7）：80B TP4。
- 物理卡 0、1：用于 35B/9B 的重复测试，或保持空闲作为健康对照。

80B 与占用逻辑 4、5 的 30B 不得同时启动。

10. 正式验收标准

一个配置只有同时满足以下条件，才可标记为正式可用：

- C1/C16 各 64 个请求全部完成，failed 为 0。
- 每个请求实际生成 1024 tokens，不能把截断响应计入吞吐。
- 跨至少两张物理卡重复后，C16 Decode TPS 变异不超过 5%。
- 高吞吐候选相对当前正式配置的收益至少为 3%，或在吞吐持平时带来明确 TTFT 改善。
- Graph 确实捕获并回放；MTP 配置有实际 draft/accepted 证据。
- 无设备核心错误、通信 reset、后端 fatal error 或残留容器。

- 测试后逻辑设备显存回落到约 500–540 MiB 的空闲范围。
- 启动参数中不包含 --disable-custom-all-reduce。

11. 阶段性结论

近期最值得投入的工作是完成 35B D 组和 80B Graph64 组的正式复测，而不是继续无边界扩大参数矩阵。9B 已具备较明确的高吞吐部署方案，下一步重点是 DP2 的负载均衡和稳定性；30B 则应围绕无 EP 的 TP2 路线继续优化 async、batch 和 MoE backend。EP、自动 KV（80B）以及尚未证明兼容的编译融合选项应从主线中隔离，先作为独立稳定性课题处理。

相关结果目录：

- /data/infra/benchmarks/gr308-35b-mtp4-short-matrix-ready-20260915/
- /data/infra/benchmarks/gr308-35b-two-card-tps-20260915/
- /data/infra/benchmarks/gr308-final-high-throughput-20260915/
- /data/infra/benchmarks/gr308-80b-short-tuning-20260915/