性能测试数据研究报告

风华 GR308 Wan2.2
视频生成性能测试与调优报告

SGLang Diffusers | 1280×704 | VAE 混合精度 | 质量验证 | 121 帧完整负载诊断

测试对象：Wan2.2-TI2V-5B-Diffusers。

平台：8 张 GR308 物理卡 / 16 个逻辑设备；单物理卡 56 GiB；驱动 1.1.0.21。

短测：TP2、请求 1 帧但运行时实际调整为 5 帧、3 steps、固定 prompt/seed。

短测 E2E 降幅	VAE decode 加速	S2 首帧 SSIM
43.5% S2 vs FP32	1.82x 1144.41 s -> 630.31 s	0.9743 单 prompt / seed

一、结论摘要

结论 1 | S2 是当前短测最优候选。端到端从 1190.20 s 降至 672.33 s，VAE decode 从 1144.41 s 降至 630.31 s。

结论 2 | S2 首帧质量接近 FP32 工程参考。PSNR 39.36 dB、luma SSIM 0.9743、RGB SSIM 0.9617；但样本量只有一帧。

结论 3 | 全局 FP16 必须拒绝。尽管 E2E 降低约 68%，但 PSNR 仅 14.25 dB，并出现确定性条带、块状断裂和颜色漂移。

结论 4 | VAE decode 是绝对瓶颈。FP32 基线中占 E2E 约 96.2%，普通驻留和拓扑调整不足以改变该结构。

结论 5 | 121 帧/20 步尚未跑通。已确认 firmware semaphore timeout、异常 HIP OOM 和 SP8 backend 能力限制，因此不能报告同口径 GR308/RTX 5090 倍率。

二、测试口径、证据等级与基线

项目	短测	完整目标
分辨率	1280×704	1280×704
帧数	CLI 1；运行时实际 5	121
Denoise steps	3	20
采样	UniPC / guidance 5 / seed 42	UniPC / shift 5 / guidance 5 / seed 42
证据	成功输出 + perf.json + 首帧	目前无成功 perf.json

证据分级：成功且具有完整 perf.json
的结果用于性能比较；完成首帧全参考指标的结果可作为质量候选；未成功的容器日志只用于诊断。

关键口径修正：短测命令中的 num_frames=1 被 SGLang 在双卡条件下调整为 5 帧。报告统一按“有效 5 帧短测”描述，避免误写成单帧性能。

基线复现性

指标	均值/s	标准差/s	最小/s	最大/s
E2E	1192.43	2.00	1190.16	1195.23
VAE decode	1146.46	0.85	1145.53	1147.84

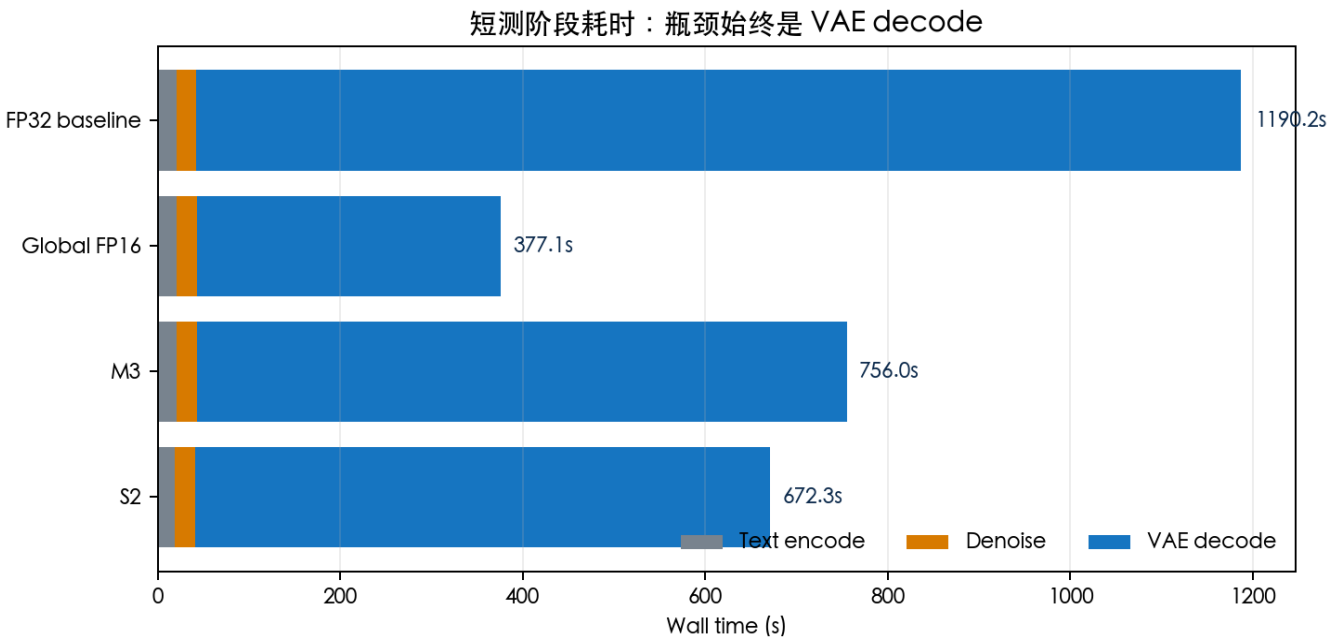


图 1：四个代表配置的阶段耗时。即使采用 S2，VAE decode 仍占主要部分。

三、混合精度优化矩阵

方案	精度边界	E2E/s	Decode/s	降幅	峰值/MiB	判断
FP32 baseline	VAE FP32-effective; TP2; VAE CPU offload	1190.20	1144.41	-	25178	参考
Global FP16	VAE decode FP16; all decoder blocks	377.14	333.47	70.9%	27595	质量拒绝
M0	FP16 early path only; 0 up blocks	1184.34	1138.27	0.5%	24667	收益小
M1	FP16 early path + 1 up block	1151.72	1106.83	3.3%	24312	收益有限
M2	FP16 early path + 2 up blocks	1029.46	987.54	13.7%	24069	有效
M3	FP16 early path + 3 up blocks; final stage FP32	756.04	712.45	37.7%	22195	质量候选
S1	M3 + final block last 1 residual unit FP16	710.02	668.04	41.6%	24410	有效
S2	M3 + final block last 2 residual units FP16	672.33	630.31	44.9%	24403	短测最优

主要规律：M0/M1 的收益接近基线波动；M2 开始进入有效区间；M3、S1、S2 表明高分辨率 up block 与最终 residual unit 是主要性能来源。

精度边界：继续将倒数第 3 个高分辨率 residual unit 切到 FP16，会触发 5.80 GiB Conv3D 工作区分配失败。

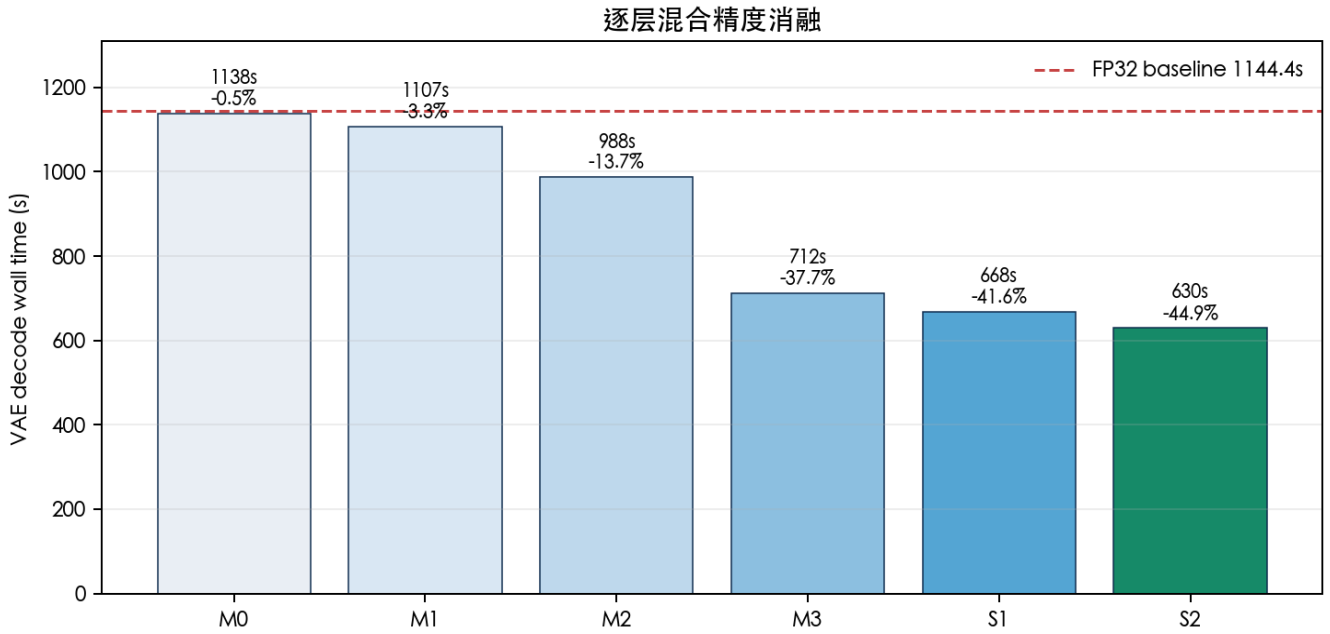


图 2：VAE 混合精度路径。S2 的 decode 降幅为 44.9%。

四、生成质量验证

方案	PSNR/dB	Luma SSIM	RGB SSIM	MAE/255	P95 误差	判断
Global FP16	14.254	0.7019	0.5996	38.50	103	拒绝
M3	39.376	0.9745	0.9624	1.66	6	候选
S2	39.361	0.9743	0.9617	1.66	6	候选

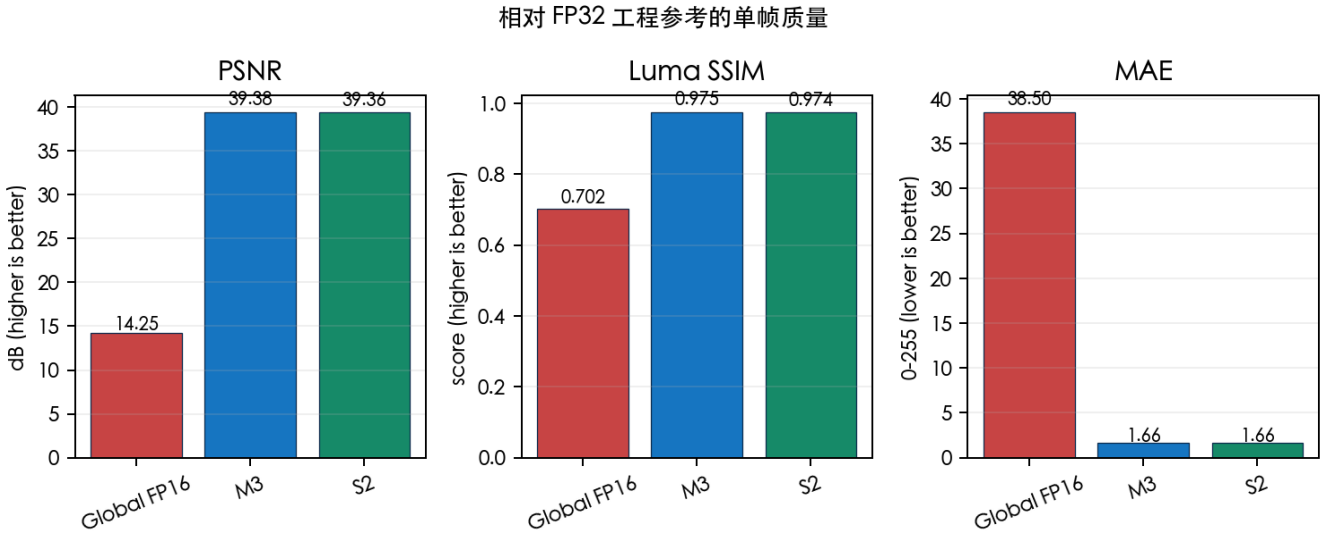


图 3：相对 FP32 工程参考的首帧全参考指标。

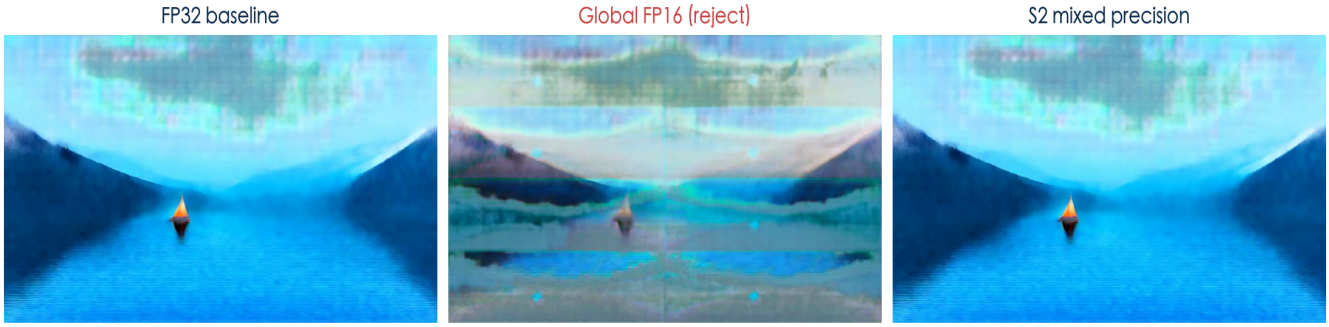


图 4：同 prompt、seed 的 FP32、Global FP16 与 S2 首帧。Global FP16 存在明显结构与颜色损坏。

解释边界：只有一个 prompt、一个 seed 和一个对齐首帧；没有覆盖闪烁、运动一致性、时序漂移与跨场景稳定性。

五、121 帧/20 步完整负载状态

路径	负载	失败表现	工程判断
F1/F2 and Wave6 selective Conv3D	short 1280x704, effective 5 frames, 3 steps	VAE decode HIP OOM while requesting a 5.80 GiB allocation despite about 29-31 GiB reported free	FP16 high-resolution Conv3D workspace / virtual-address allocation boundary
Full S2 TP2	1280x704, 121 frames, 20 steps	FANT DMA and firmware semaphore timeout during denoise	long-sequence distributed execution / firmware synchronization failure
Full S2 SP2	1280x704, 121 frames, 20 steps	denoise step 0 HIP OOM; 160 MiB requested with about 23.34 GiB reported free	allocator or address-space failure rather than nominal capacity exhaustion
Full S2 SP4	1280x704, 121 frames, 20 steps	denoise step 0 HIP OOM; 80 MiB requested with about 23.15 GiB reported free	greater parallelism reduced request size but did not remove allocator failure
Full SP8 ring	1280x704, 121 frames, 20 steps	native Diffusers fallback cannot honor sp_degree=8/ring_degree=8; Fantasy adapter permits only Torch SDPA	software capability boundary before execution

TP2：文本编码结束后，在长序列 denoise 阶段触发 DMA/firmware semaphore 30 s timeout。

SP2/SP4：分别把失败申请缩小到 160 MiB 和 80 MiB，但在仍报告约 23 GiB 空闲时 OOM，说明问题不能用“显存容量不够”简单解释。

SP8：native Diffusers fallback 无法执行请求的 SP/ring 拓扑，同时实验 Fantasy adapter 只允许 Torch SDPA，运行前即失败。

多个 sequence-shard、offload 和 allocator 变体未形成有效 perf.json，因此不计入性能矩阵。

外部 RTX 5090 参考

既有记录为 8×RTX 5090、1280×704、121 帧、3 步：U8+CFG1 57.206 s，U4+CFG2 37.222 s，后者快 1.5369×。GR308 尚无同口径完成结果，不能计算速度比。

六、高分辨率 Conv3D 深挖

尝试	卡数	变化	结果
局部 autocast	2	仅目标 residual 的两次 Conv3D FP16	OOM
权重预转换	2	提前缓存 FP16 Conv3D 权重	OOM
扩大空间切分	4	TP4，缩小单卡空间分片	OOM；denoise 57 s -> 86.9 s
整块 FP16	2	倒数第 3 个 residual 整体 FP16	OOM

四种写法都在同一高分辨率阶段失败。最完整日志显示：单次申请 5.80 GiB，GPU 报告仍有约 28.92 GiB 空闲，却返回 HIP OOM。

这更符合 FP16 Conv3D 算法的大工作区、PAL 虚拟地址分配或后端 allocator 交互问题，而不是模型静态权重无法容纳。

从 GR308 文档可确认的工具只有 HIP 默认内存池、hipMallocAsync/hipFreeAsync、hipMemPoolTrimTo、hipMemGetInfo，以及 FHCCL 的 ALLOC/GRAPH/TUNING 日志。文档没有给出 Conv3D workspace limit、算法枚举或 PYTORCH_FANT_ALLOC_CONF 的正式说明。

因此下一步应从参数调优转向：带 halo 的空间 tiled Conv3D、厂商低 workspace 算法、PAL/allocator 最小复现与固件修复。

当前可运行边界

S2 保留高风险高分辨率 residual、归一化和输出头的 FP32 路径，仅将已验证的 up blocks 与最后两个低风险 residual unit 下沉至 FP16。进一步扩大 FP16 范围尚无可运行证据。

七、推荐配置、部署判断与路线

用途	建议	状态
短测回归	S2：FP16_UP_BLOCKS=3，FP16_FINAL_RESNETS=-2	推荐
全局 FP16	禁止；确定性质量损坏	拒绝
121 帧生产	等待 firmware、allocator 和 SP backend 问题修复	未就绪
扩卡	不要假设卡数越多越快；TP4 已显示通信回归	需单独验证

S2 关键配置

```
SGLANG_WAN_VAE_FP16_UP_BLOCKS=3
SGLANG_WAN_VAE_FP16_FINAL_RESNETS=-2
--vae-precision fp32 --vae-decode-precision fp16
--vae-config.use-parallel-decode true --vae-config.parallel-decode-mode auto
```

该配置依赖定制 Wan VAE 混合精度实现；只设置原生 vae-decode-precision=fp16 会进入全局 FP16，不等价于 S2。

优先级

优先级	工作项
P0	构造 FP16 Conv3D 最小复现，确认 5.80 GiB workspace 来源与可配置上限
P0	修复 121 帧 denoise 的 firmware semaphore timeout
P1	实现带 halo 的 tiled Conv3D，并做逐层数值验证
P1	用 hipMemGetInfo 与 FHCCL ALLOC/GRAPH/TUNING 日志区分 allocator/PAL/通信
P2	完整负载打通后再跑 U8+CFG1、U4+CFG2、TP/SP/CFG 正式矩阵
P2	扩展多 prompt、多 seed、121 帧时序质量与人工盲检

最终部署判断：当前 GR308 软件栈能够完成 Wan2.2 短视频短测并通过选择性混合精度显著加速，但尚未证明可稳定承载目标 121 帧/20 步任务。

八、限制与复现索引

统计限制：性能消融是工程短测；质量样本 n=1；没有置信区间或显著性检验。

指标限制：PSNR/SSIM 是相对 FP32 工程参考的一致性，不代表绝对审美质量或文本一致性。

系统限制：失败可能同时涉及 SGLang distributed fallback、Fantasy adapter、PyTorch allocator、PAL VA manager 和固件同步；现有日志不足以唯一归因。

外推限制：5 帧/3 步短测不能外推到 121 帧/20 步；没有有效的 GR308/RTX 5090 同口径比例。

复现索引

内容	位置
结构化数据	output/风华_GR308_Wan2.2视频生成性能测试与调优报告_20260918/data/report_data.json
可编辑正文	output/风华_GR308_Wan2.2视频生成性能测试与调优报告_20260918/*.md
质量原图与视频	output/wan22_quality/
质量计算脚本	tools/compare_wan22_quality.py
VAE 混合精度实现	tools/fantasy_wanvae_mixed.py
短测启动脚本	tools/run_wan22_matrix_job.sh

报告中的性能数字均来自成功 perf.json；失败表来自对应容器日志。未成功产生 perf.json 的配置不参与排名。